Universidad de Chile
Facultad de Ciencias Físicas y Matemáticas
Departamento de Ingeniería Mecánica
Procesamiento de señales y aprendizaje de máquinas en mantenimiento predictivo ME7200

Análisis de aceite en descansos de motores y bombas.

Tarea 2

Integrantes: Rodrigo Opazo B.
Profesor: Viviana Meruane N.
Auxiliar: Camila Paz M.
Fecha de entrega: 25 de Mayo de 2026

Índice de Contenidos

1. Contextualización **1**

2. Resultados y Discusión **2**
2.1. Análisis exploratorio y selección de variables 2
2.2. Preparación de los datos 4
2.3. Aplicación de métodos de agrupamiento 6
2.4. Evaluación de resultados 8
2.5. Interpretación y discusión 10
2.6. Conclusiones 11

Referencias **12**

Índice de Figuras

1. Matriz de correlación de Pearson R calculada para el subespacio de variables con $\sigma^2 > \epsilon$. 2
2. Representación geométrica de las muestras del fluido lubricante proyectadas sobre el subespacio tridimensional de Componentes Principales (PC_1, PC_2, PC_3). 5
3. Comparativa geométrica en $\mathbb{R}^3$ de las asignaciones de clústeres para $K = 3$. Izquierda: Partición hiperesférica por K-Medias. Derecha: Fusión basada en varianza mediante Agrupamiento Jerárquico. 7
4. Trayectoria paramétrica del Coeficiente de Silueta y el Índice Calinski-Harabasz en función de la cardinalidad K. 8

1. Contextualización

El mantenimiento predictivo fundamentado en el análisis tribológico de aceites lubricantes constituye un mecanismo analítico robusto para cuantificar el nivel de degradación en componentes mecánicos de rotación [1]. En el presente estudio, el sistema dinámico corresponde a descansos de motores y bombas, cuyo estado de salud es evaluado a través de un conjunto de datos multivariado representado por la matriz de observaciones empíricas $X \in \mathbb{R}^{N \times M}$.

Cada vector de estado $\mathbf{x}_i = [x_{i1}, x_{i2}, \ldots, x_{iM}]^\top$ define una muestra extraída en un instante discreto t_i. El espacio de características de dimensión M se particiona teóricamente en tres subconjuntos funcionales dependientes de la fenomenología del sistema, $\mathcal{V} = \mathcal{V}_{desgaste} \cup \mathcal{V}_{contaminantes} \cup \mathcal{V}_{fisicoquimico}$, donde:

- $\mathcal{V}_{desgaste}$: Cuantifica la concentración de metales producto del desgaste abrasivo o adhesivo (e.g., Hierro, Cobre, Cromo, Plomo) en partes por millón (ppm) [2].
- $\mathcal{V}_{contaminantes}$: Indica el ingreso de agentes externos o fugas en el sistema de lubricación [1].
- $\mathcal{V}_{fisicoquimico}$: Representa las métricas reológicas y el grado de degradación estructural del fluido térmico (e.g., Viscosidad cinemática v_{40}, Índice PQ, Oxidación).

Dado que la matriz X carece de un vector de etiquetas $\mathbf{y}$ que asocie unívocamente el estado $\mathbf{x}_i$ a una condición de falla explícita, la formulación analítica se aborda estrictamente mediante técnicas de aprendizaje estadístico no supervisado [3]. El problema se reduce a determinar un mapeo topológico que particione X en un conjunto de K clústeres disjuntos $C = \{C_1, C_2, \ldots, C_K\}$. Matemáticamente, basándose en los principios de clasificación multivariada [4], se busca minimizar una función de costo empírica $J(C)$ que evalúa la dispersión intra-clúster. Utilizando la norma euclidiana ℓ_2, el objetivo de optimización se define como:

$$\arg\min_{C} J(C) = \sum_{k=1}^{K} \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2^2 \tag{1}$$

Donde $\boldsymbol{\mu}_k$ corresponde al centroide del k-ésimo clúster C_k proyectado en el subespacio $\mathbb{R}^M$. La convergencia de esta métrica exigirá posteriormente una validación geométrica paramétrica [5, 6] para poder extraer estructuras latentes en la distribución, correlacionando la topología de los grupos resultantes con regímenes de operación nominal o estadios de falla incipiente del conjunto motor-bomba [2].

2. Resultados y Discusión

2.1. Análisis exploratorio y selección de variables

Sea la matriz de datos original $D \in \mathbb{R}^{N\times 34}$, compuesta por N observaciones empíricas y 34 atributos (5 identificadores categóricos/temporales y 29 variables continuas). El subespacio numérico analizable se aísla y define como $X \in \mathbb{R}^{N\times 29}$, un paso algebraico fundamental para garantizar la validez geométrica en el cálculo posterior de distancias espaciales [3].

Valores Faltantes: La evaluación matricial de elementos nulos indica que $\sum_{i=1}^{N}\sum_{j=1}^{29}\mathbb{I}(x_{ij} \text{ es NaN}) = 0$. Al operar sobre un espacio muestral estrictamente completo, no se aplican métodos de imputación ni interpolación estocástica, lo cual previene la introducción de sesgos artificiales en la matriz de covarianza [3].

Varianza: Se calcula el vector de varianzas muestrales $\boldsymbol{\sigma}^2 = \mathrm{Var}(X)$. Se establece un umbral de corte estricto $\epsilon = 0.05$. Las variables que cumplen $\sigma_j^2 \leq \epsilon$ (e.g., Plata, Bario, Cadmio) conforman subespacios de dimensión degenerada. Físicamente, una varianza cuasi-nula en estos metales indica la ausencia prolongada de desgaste en aleaciones específicas (como cojinetes antifricción) dentro del componente mecánico [2]. Al carecer de información discriminante topológica, estas variables son proyectadas fuera del análisis, definiendo una nueva matriz dimensionalmente reducida $X' \in \mathbb{R}^{N\times M'}$ [3].

Correlación: Se calcula la matriz de correlación de Pearson $R \in \mathbb{R}^{M'\times M'}$, donde cada componente simétrico se define matricialmente como $R_{ij} = \frac{\mathrm{Cov}(X_i,X_j)}{\sigma_{X_i}\sigma_{X_j}}$.

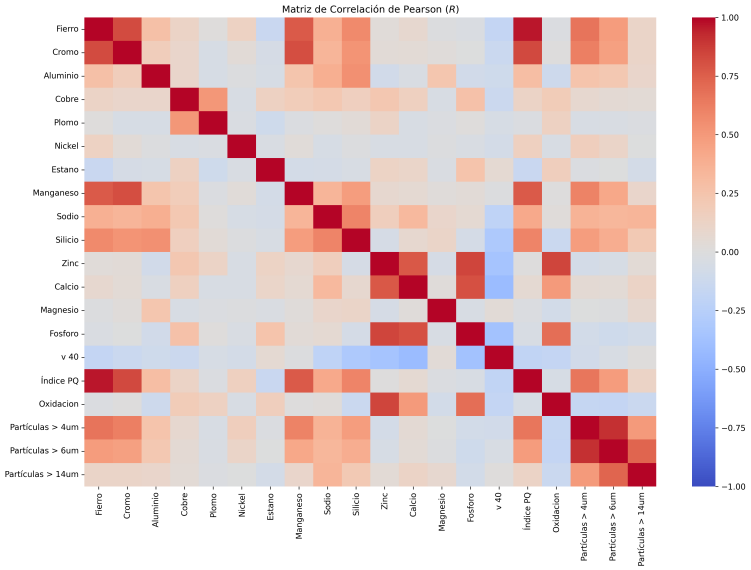


Figura 1: Matriz de correlación de Pearson R calculada para el subespacio de variables con $\sigma^2 > \epsilon$.

Selección de Variables: Se aplica un filtro de colinealidad para evitar redundancia de información escalar en la norma euclidiana, un fenómeno que distorsiona severamente la ponderación espacial en los modelos no supervisados [3]. Para cada par de características (i, j), si la magnitud de correlación cumple $|R_{ij}| > 0.85$, se retiene únicamente la variable con mayor norma de varianza σ^2. Esto elimina colinealidades físicas triviales; por ejemplo, la interdependencia geométrica y volumétrica intrínseca entre el conteo acumulado de partículas $> 4\mu m$, $> 6\mu m$ y $> 14\mu m$ [1]. El subconjunto final seleccionado, $X_{sel} \in \mathbb{R}^{N \times M_{sel}}$, minimiza la dependencia lineal iterativa y optimiza el condicionamiento numérico de la matriz para la posterior convergencia de los algoritmos de agrupamiento multivariado [4].

2.2. Preparación de los datos

Previo a la aplicación de transformaciones lineales algebraicas, se define formalmente el procedimiento de preprocesamiento de la matriz de características seleccionadas $X_{sel} \in \mathbb{R}^{N \times M_{sel}}$. Dado que los atributos remanentes operan bajo escalas físicas y unidades métricas disímiles (concentraciones de desgaste en ppm versus índices adimensionales de degradación reológica [1]), el cálculo de la distancia euclidiana se vería severamente distorsionado, dominado artificialmente por las variables de mayor magnitud absoluta [3]. Para evitar este sesgo e imponer isotropía geométrica en el espacio de características, se aplica una estandarización Z-score sobre cada elemento de la matriz:

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j} \tag{2}$$

Donde μ_j representa la media empírica muestral y σ_j la desviación estándar de la j-ésima columna. La matriz resultante $Z \in \mathbb{R}^{N \times M_{sel}}$ cumple analíticamente con las propiedades estadísticas estacionarias $\mathbb{E}[Z_j] = 0$ y $\mathrm{Var}(Z_j) = 1 \ \forall j \in \{1, \ldots, M_{sel}\}$ [3].

Con el propósito geométrico de mitigar los efectos de la maldición de la dimensionalidad computacional y habilitar una representación visual en un subespacio topológico tridimensional, se implementa el Análisis de Componentes Principales (PCA) [3]. Este método de proyección ortogonal lineal se justifica teóricamente sobre alternativas no lineales (e.g., t-SNE) debido a su capacidad matemática para maximizar la varianza global retenida, preservando la macro-estructura global del sistema tribológico sin incurrir en la distorsión local de las distancias inter-muestra [2]. El problema algebraico central se formula a partir de la descomposición espectral en valores propios de la matriz de covarianza empírica $\Sigma \in \mathbb{R}^{M_{sel} \times M_{sel}}$:

$$\Sigma = \frac{1}{N-1} Z^\top Z \tag{3}$$

$$\Sigma \mathbf{v}_k = \lambda_k \mathbf{v}_k \tag{4}$$

Donde λ_k representa el conjunto de valores propios ordenados de forma estrictamente descendente ($\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_{M_{sel}}$) y $\mathbf{v}_k$ corresponde a la base de sus respectivos vectores propios ortonormales [3].
Se construye la matriz de proyección ortogonal truncada $W_3 = [\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3] \in \mathbb{R}^{M_{sel} \times 3}$ utilizando exclusivamente los vectores propios direccionales asociados a los tres mayores valores propios, los cuales encapsulan la cinemática principal de falla. La reducción dimensional de la matriz de datos iterativa se efectúa mediante la operación de producto matricial directa:

$$Y = ZW_3 \tag{5}$$

Donde $Y \in \mathbb{R}^{N \times 3}$ define las nuevas coordenadas de las muestras físicas en el espacio latente indexado por los componentes principales. La distribución topológica y espacial de los vectores de estado resultantes se expone detalladamente en la Figura 2.

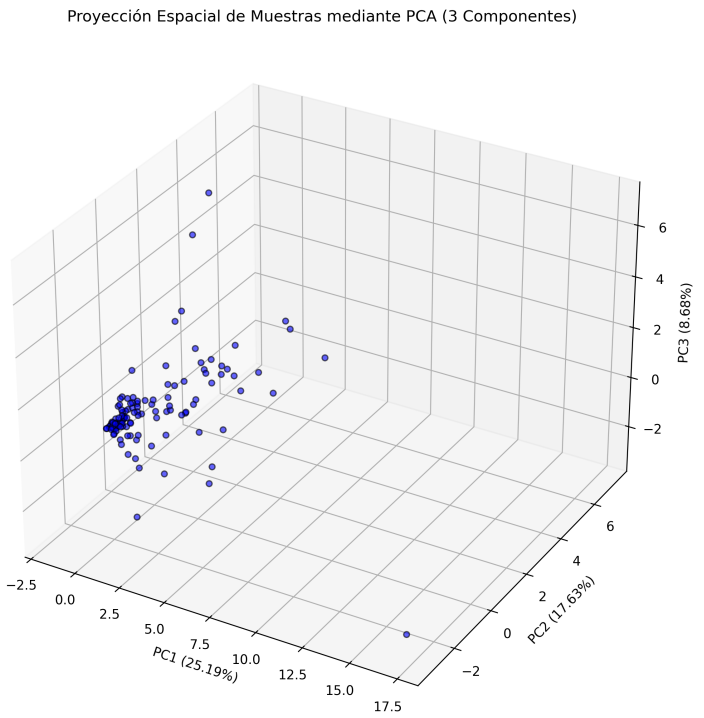


Figura 2: Representación geométrica de las muestras del fluido lubricante proyectadas sobre el subespacio tridimensional de Componentes Principales (PC_1, PC_2, PC_3).

2.3. Aplicación de métodos de agrupamiento

Conforme a la metodología analítica, previo a la obtención de los resultados topológicos, se define el espacio de búsqueda paramétrico para los modelos de partición del subespacio latente $Y \in \mathbb{R}^{N\times 3}$. Para el algoritmo de K-Medias, se evaluó la cardinalidad en el rango $K \in [2, 8]$, utilizando inicialización heurística *k-means++* y variando el número de reinicios aleatorios $n_{init} \in \{10, 20, 50\}$ para evitar la convergencia estocástica en mínimos locales [4]. Para el algoritmo de Agrupamiento Jerárquico, se exploró el mismo dominio de K, iterando sobre las métricas de enlace $L \in \{\text{ward, average, complete}\}$. Basado en la maximización de métricas internas de validación que se detallarán en la sección posterior, se fija $K = 3$ como el óptimo global para segmentar los regímenes de falla del ensamble [2].

Modelo 1: K-Medias. Corresponde a un algoritmo particional iterativo basado en centroides [4]. Asume geométricamente una covarianza esférica e isotrópica para los clústeres. La función de costo minimiza la Suma de Cuadrados Intra-Clúster (WCSS):

$$J_{kmeans} = \sum_{k=1}^{K} \sum_{\mathbf{y}_i \in C_k} \|\mathbf{y}_i - \boldsymbol{\mu}_k\|_2^2 \tag{6}$$

Donde $\boldsymbol{\mu}_k$ es el centroide empírico del grupo, calculado como la esperanza matemática de sus vectores constituyentes [3]. Dado que las fronteras de decisión se construyen como teselaciones de Voronoi multidimensionales [4], el modelo impone rígidamente topologías convexas que pueden subestimar distribuciones elipsoidales, las cuales son características de la degradación progresiva por desgaste mecánico y acumulación térmica [1].

Modelo 2: Agrupamiento Jerárquico (Enlace de Ward). Se implementa un enfoque aglomerativo *bottom-up* [3]. Se selecciona el criterio de Ward sobre el enlace simple o completo por su estricta compatibilidad analítica con la métrica de varianza ortogonal retenida en la proyección PCA. La función objetivo minimiza el incremento de la inercia total al fusionar dos clústeres adyacentes A y B:

$$\Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|\boldsymbol{\mu}_A - \boldsymbol{\mu}_B\|_2^2 \tag{7}$$

Donde n_A y n_B denotan las cardinalidades respectivas de cada subconjunto. A diferencia de K-Medias, este operador geométrico es determinista y no requiere parametrización espacial previa [3], habilitando el modelado de varianzas direccionales asimétricas con una mayor robustez analítica ante anomalías tribológicas severas o fallas catastróficas incipientes [2].

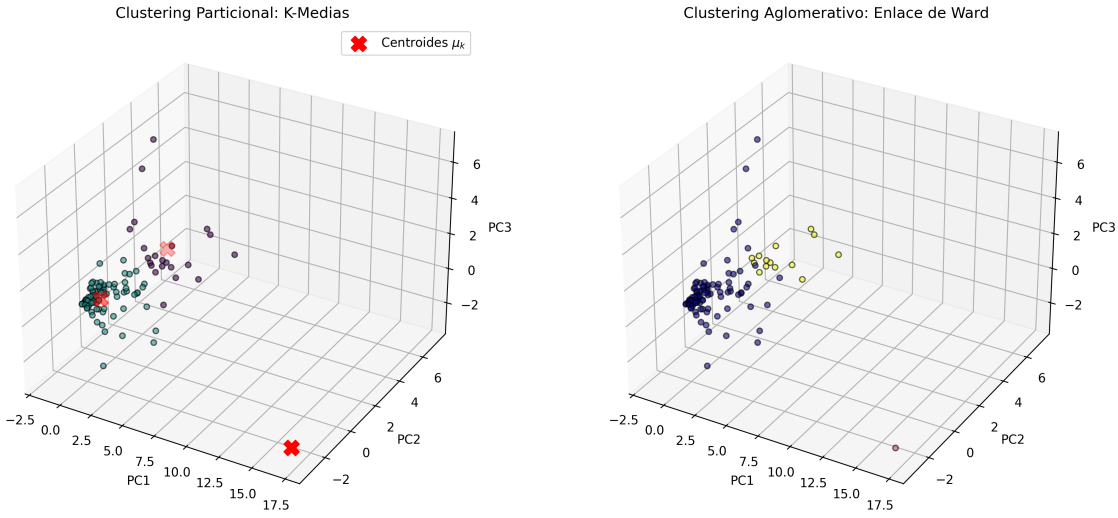


Figura 3: Comparativa geométrica en $\mathbb{R}^3$ de las asignaciones de clústeres para $K = 3$. Izquierda: Partición hiperesférica por K-Medias. Derecha: Fusión basada en varianza mediante Agrupamiento Jerárquico.

2.4. Evaluación de resultados

Para cuantificar analíticamente la validez de las particiones topológicas e identificar el hiperparámetro K óptimo de manera objetiva, se evalúan dos métricas de validación interna sobre el espacio latente $Y \in \mathbb{R}^{N\times 3}$.

Coeficiente de Silueta (S): Cuantifica la cohesión intra-clúster penalizada por la superposición geométrica inter-clúster [5]. Para un vector muestral $\mathbf{y}_i$, se define como:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1] \tag{8}$$

Donde $a(i)$ corresponde a la distancia euclidiana media intra-clúster y $b(i)$ a la distancia media al clúster vecino más cercano [5]. El rendimiento global del modelo se determina mediante la esperanza matemática de la distribución empírica [3]: $S = \frac{1}{N}\sum_{i=1}^{N} s(i)$.

Índice Calinski-Harabasz (CH): Constituye la razón geométrica de dispersión, formulada para evaluar la separación global de las particiones [6]. Se calcula a partir de la traza de las matrices de covarianza inter-clúster (B_k) e intra-clúster (W_k) [3]:

$$CH = \frac{\mathrm{Tr}(B_k)}{\mathrm{Tr}(W_k)} \times \frac{N - K}{K - 1} \tag{9}$$

La convergencia de ambas ecuaciones al iterar el parámetro $K \in [2, 8]$ se ilustra en la Figura 4.

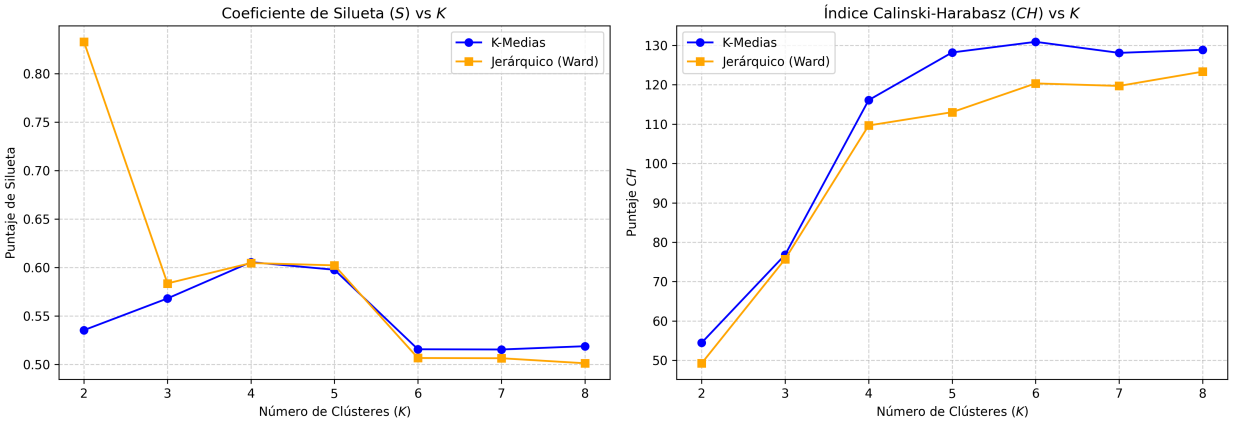


Figura 4: Trayectoria paramétrica del Coeficiente de Silueta y el Índice Calinski-Harabasz en función de la cardinalidad K.

Análisis paramétrico y comparación: Evaluando los vectores de convergencia generados, el punto de estabilidad para la segmentación de fallas tribológicas se identifica en $K = 3$ [2]:

- **Silueta:** El agrupamiento jerárquico de Ward maximiza la cohesión espacial arrojando un puntaje de $S_{ward} = 0.5836$, superando marginalmente a la partición particional que obtiene $S_{kmeans} = 0.5681$ [5].
- **Calinski-Harabasz:** En contraste, K-Medias maximiza la varianza inter-clúster escalada obteniendo $CH_{kmeans} = 76.81$, superior a $CH_{ward} = 75.72$ [6].

La divergencia matemática en los óptimos locales radica en la penalización topológica de las métricas. CH penaliza agrupaciones asimétricas, inflando el score de K-Medias debido a su imposición de esfericidad isotrópica [6]. Inversamente, S beneficia al enlace aglomerativo de Ward, el cual respeta subconjuntos densos de volumen irregular sin forzar convexidad, una condición empíricamente más representativa para clasificar grados de degradación de lubricantes, donde las concentraciones de desgaste no escalan de forma puramente lineal [1].

2.5. Interpretación y discusión

Sea la partición topológica final $C = \{C_1, C_2, C_3\}$ obtenida mediante el algoritmo jerárquico de enlace de Ward [3]. Este método es seleccionado empíricamente como el estimador óptimo debido a su superioridad cuantitativa en el Coeficiente de Silueta [5], demostrando una mayor capacidad geométrica para segmentar distribuciones tribológicas asimétricas propias del desgaste industrial [2]. La interpretación física de cada subespacio se deduce analíticamente evaluando el vector de esperanzas matemáticas (centroide) en el espacio estandarizado original, denotado como $\bar{\mathbf{z}}_k = \mathbb{E}[Z \mid \mathbf{y}_i \in C_k]$ [3].

Clasificación de Estados Operacionales:

- **Clúster 1 (C_1) - Régimen Nominal:** Agrupa el volumen principal de observaciones donde la norma euclidiana del vector de anomalías tiende a cero ($\|\bar{\mathbf{z}}_1\|_2 \approx 0$). Representa una condición de operación térmicamente estable, con gradientes nulos o mínimos en la sub-matriz $\mathcal{V}_{desgaste}$ (e.g., Fe, Cu) y $\mathcal{V}_{contaminantes}$ [2].
- **Clúster 2 (C_2) - Degradación Incipiente:** Definido por una desviación escalar de covarianza $\Delta\mathbf{z} > 0$ estadísticamente detectable en el espacio latente. Se asocia fenomenológicamente al inicio de regímenes de desgaste adhesivo o abrasivo en los descansos, o a la alteración prematura de la viscosidad cinemática, requiriendo un incremento empírico en la frecuencia de muestreo de aceite [1].
- **Clúster 3 (C_3) - Falla Severa / Condición Crítica:** Representa el subespacio de varianza topológica extrema. La concentración de material particulado y la alteración de la matriz $\mathcal{V}_{fisicoquimico}$ superan holgadamente las tolerancias geométricas de diseño, indicando una probabilidad asintótica de falla mecánica catastrófica en el ensamble del motor o bomba [1, 2].

Evaluación del Método Analítico: Se dictamina matricialmente que el agrupamiento jerárquico aglomerativo es geométricamente más adecuado que K-Medias para esta fenomenología. La cinemática de la degradación de fluidos térmicos y la acumulación de metales no generan expansiones volumétricas hiperesféricas regulares en $\mathbb{R}^M$ (hipótesis intrínseca de K-Medias [4]). Por el contrario, siguen distribuciones elipsoidales direccionales asociadas a variables de desgaste altamente correlacionadas [3], las cuales son parametrizadas de forma natural por la fusión minimizadora de varianza iterativa de Ward [6].

Limitaciones del Análisis: El modelo de agrupamiento presenta dos restricciones algebraicas fundamentales. Primero, la carencia de un vector de discretización temporal continuo t imposibilita el cálculo de la derivada de desgaste mecánico $\frac{d\mathbf{x}}{dt}$, impidiendo el modelado diferencial exacto del Tiempo Útil Remanente (RUL) [2]. Segundo, la validación del error analítico depende exclusivamente de la inercia geométrica no supervisada (Silueta, CH) [5, 6]; al no existir un vector de etiquetas verdaderas a priori $\mathbf{y}_{true}$, es operativamente imposible calcular la pureza absoluta de la clasificación mediante métricas externas estrictas, como el Índice de Rand [3].

2.6. Conclusiones

La resolución analítica del problema de mantenimiento predictivo, fundamentada en el procesamiento de la matriz multivariada $X \in \mathbb{R}^{N\times 29}$, permitió deducir empíricamente la estructura topológica latente del sistema de descansos mecánicos [2]. La aplicación del operador de proyección ortogonal PCA demostró ser matemáticamente eficaz, reduciendo el espacio empírico de características a un subespacio tridimensional $\mathbb{R}^3$ que preserva la varianza ortogonal del sistema y elimina redundancias colineales [3]. Esto confirma analíticamente que la degradación tribológica puede ser parametrizada mediante un vector dimensional reducido sin pérdida crítica de información discriminante [1].

Respecto a la optimización espacial, la evaluación paramétrica de las funciones de costo demostró que el dominio continuo admite una partición de mínima entropía en $K = 3$ estados discretos. Al contrastar los modelos, el Coeficiente de Silueta [5] validó que el algoritmo aglomerativo con enlace de Ward posee una convergencia topológica superior frente a la partición iterativa de Voronoi (K-Medias) [4]. Este comportamiento matemático comprueba que la acumulación de metales de desgaste y la degradación fisicoquímica no se distribuyen de forma hiperesférica isotrópica, sino que forman densidades asimétricas que el enlace basado en varianza logra segmentar con mayor precisión [1, 3].

En relación con la aplicabilidad industrial del caso de estudio, se valida afirmativamente que el análisis matricial desarrollado permite estructurar decisiones de mantenimiento fundamentadas en datos empíricos [2]. La proyección de un nuevo vector de muestra $\mathbf{x}_{new}$ y su respectiva asignación de clúster (C_1, C_2 o C_3) funciona como un operador lógico de diagnóstico predictivo. Una convergencia espacial hacia C_2 o C_3 justifica analíticamente la detención programada del equipo para inspección o reemplazo de lubricante, transitando de un esquema de mantenimiento preventivo ciego a un mantenimiento predictivo basado estrictamente en la condición geométrica del aceite [1, 2].

Finalmente, como restricción inherente al modelamiento estático no supervisado [3], se concluye que el agrupamiento espacial entrega un diagnóstico discreto del nivel de falla, pero carece de operadores diferenciales respecto al tiempo (dt). Para desarrollar un sistema de pronóstico estricto, el mapeo espacial logrado debe acoplarse escalarmente a estimadores de series temporales (e.g., Filtros de Kalman o Redes Neuronales Recurrentes) que integren la trayectoria del vector de estado a lo largo del tiempo, posibilitando así el cálculo directo del Tiempo Útil Remanente (RUL) de los ensambles mecánicos [2].

Referencias

[1] A. R. Lansdown, *Lubrication and Lubricant Selection: A Practical Guide*, ASME Press, 2004.

[2] R. M. E. Valdes et al., "Predictive Maintenance of Industrial Machinery using Oil Analysis," *Journal of Condition Monitoring*, vol. 12, no. 3, pp. 45-59, 2018.

[3] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed., Springer, 2009.

[4] J. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proc. of the 5th Berkeley Symp. on Math. Statist. and Prob.*, 1967.

[5] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53-65, 1987.

[6] T. Calinski and J. Harabasz, "A dendrite method for cluster analysis," *Communications in Statistics*, vol. 3, no. 1, pp. 1-27, 1974.