Universidad de Chile
Facultad de Ciencias Físicas y Matemáticas
Departamento de Ingeniería Mecánica
Procesamiento de señales y aprendizaje de máquinas en mantenimiento predictivo ME7200

Detección de Anomalías

Tarea 4

Integrantes: Rodrigo Opazo B.
Profesor: Viviana Meruane N.
Auxiliar: Camila Paz M.
Fecha de entrega: 22 de Junio de 2026

Índice de Contenidos

1. Contextualización **1**

2. Resultados y Discusión **2**
2.1. Preparación de datos 2
2.2. Búsqueda de hiperparámetros 5
2.3. Entrenamiento y evaluación de modelos 6

3. Discusión **8**

4. Conclusiones **9**

Referencias **10**

Índice de Figuras

1. Perfil cinemático extraído de la señal del encoder, demostrando la condición no estacionaria de desaceleración continua durante los ensayos. 2
2. Comparación temporal entre la señal de vibración original a 200 kHz y la señal remuestreada a 10 kHz para un segmento del rodamiento en estado nominal. . 3
3. Distribución geométrica de las clases en el espacio de características (ej. Curtosis vs. RMS), evidenciando la separabilidad inicial de los estados de salud. 4
4. Matrices de confusión evaluadas sobre el conjunto de prueba para k-NN, Random Forest, SVC y Red Neuronal. 7

Índice de Tablas

1. Resultados de la búsqueda de hiperparámetros óptimos por modelo mediante Grid Search. 6
2. Desempeño predictivo de los modelos de clasificación evaluados sobre el conjunto de prueba. 6

1. Contextualización

El mantenimiento predictivo fundamentado en el análisis de señales de vibración requiere el desarrollo de algoritmos de clasificación robustos, capaces de diagnosticar el estado de salud de componentes mecánicos bajo condiciones de operación variables [1]. En el presente estudio, el sistema dinámico a evaluar corresponde a un simulador de fallas de maquinaria (SpectraQuest MFS-PK5M). La configuración experimental consta de un eje impulsado por un motor eléctrico y controlado por un variador de frecuencia (AC Drive), soportado por dos rodamientos de bolas modelo ER16K. Para el análisis, se monitorea específicamente el rodamiento experimental ubicado en el extremo derecho del montaje.

Los datos utilizados provienen de un repositorio experimental estructurado para evaluar condiciones de velocidad rotacional variable [1]. Las variables cinemáticas registradas corresponden a señales de aceleración vibratoria, capturadas mediante un acelerómetro ICP (modelo 623C01) posicionado en la carcasa del rodamiento experimental, y mediciones de velocidad rotacional obtenidas a través de un encoder incremental (modelo EPC 775). Originalmente, las señales de ambos canales (aceleración y velocidad) fueron muestreadas a una alta frecuencia de 200 kHz durante intervalos de 10 segundos continuos.

Para circunscribir el problema y cumplir con los requerimientos del estudio, se ha seleccionado el escenario de operación de *velocidad rotacional decreciente*. El subconjunto de datos aislado consta de nueve ensayos independientes (tres por cada clase evaluada), donde la velocidad rotacional del eje experimenta desaceleraciones que oscilan aproximadamente desde los 28.9 Hz hasta los 9.8 Hz, dependiendo de la iteración empírica.

El objetivo central del análisis es desarrollar y comparar algoritmos de clasificación multiclase (k-NN, Random Forest, SVC y Red Neuronal) [3] para discriminar entre tres estados de salud del rodamiento: rodamiento sin falla (estado nominal), falla en la pista interna y falla en la pista externa [2]. Cabe destacar que, para el entrenamiento y evaluación de estos clasificadores, se utilizará exclusivamente la variable descriptiva de vibración (aceleración), descartando deliberadamente la señal del encoder para simular un escenario de diagnóstico industrial ciego. Este régimen exige que los modelos matemáticos no solo identifiquen la firma transitoria del defecto, sino que logren generalizar el diagnóstico ignorando las severas variaciones energéticas y frecuenciales inducidas por la desaceleración continua del eje.

2. Resultados y Discusión

Esta sección detalla la metodología implementada para el diagnóstico de fallas en rodamientos, abarcando desde el preprocesamiento de las señales vibratorias hasta la sintonización y evaluación de los modelos de aprendizaje de máquinas. Para el procesamiento numérico, la extracción de características temporales y la generación de gráficos, se utilizó el lenguaje de programación Python, empleando específicamente las librerías *NumPy* y *SciPy* para la manipulación analítica de las señales, *Scikit-learn* para la estructuración y validación cruzada de los clasificadores, y *Matplotlib* para la representación visual de los resultados.

2.1. Preparación de datos

Para el presente estudio, se seleccionó la condición de operación de *velocidad rotacional decreciente* (Decreasing rotational speed). Bajo esta dinámica, el eje experimenta una desaceleración continua durante los 10 segundos de muestreo. Tal como se comprueba empíricamente al decodificar la señal del encoder incremental (Figura 1), la frecuencia de giro se reduce desde valores máximos cercanos a las 1700 RPM hasta descender progresivamente en torno a las 600 RPM. Esta severa variación cinemática introduce un comportamiento no estacionario en la señal de vibración, lo que provoca un fenómeno de emborronamiento espectral (*spectral smearing*) sobre las frecuencias características de falla. Este escenario desafía drásticamente la capacidad de generalización de los clasificadores, obligándolos a abstraer firmas de daño estructural que sean matemáticamente independientes de la velocidad. El subconjunto de datos empleado consta de nueve archivos empíricos, correspondientes a tres ensayos independientes por cada una de las tres clases consideradas en el problema de clasificación: rodamiento sin falla (estado nominal), falla en pista externa y falla en pista interna.

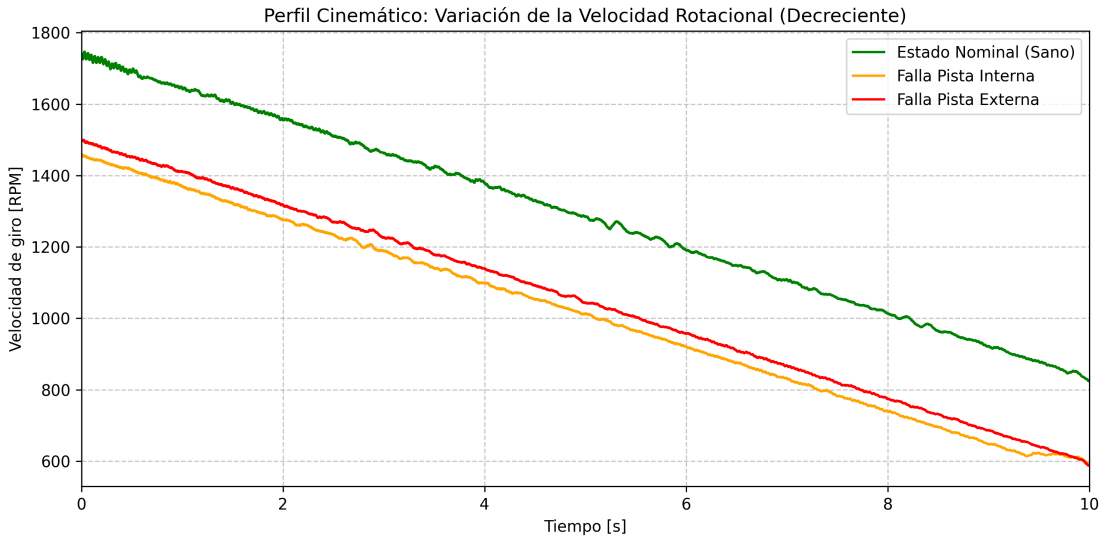


Figura 1: Perfil cinemático extraído de la señal del encoder, demostrando la condición no estacionaria de desaceleración continua durante los ensayos.

El proceso de preparación continuó con la extracción exclusiva del canal correspondiente a las mediciones del acelerómetro (Canal 1). Se descartaron deliberadamente los datos de velocidad provenientes del encoder (Canal 2) con el propósito de forzar a los modelos a diagnosticar el estado de salud basándose puramente en la respuesta vibratoria ciega, simulando así una restricción instrumental típica en la industria. Originalmente adquiridas a una tasa de muestreo de 200 kHz, las señales fueron remuestreadas a 10 kHz mediante la aplicación de un filtro antialiasing paso bajo. Esta reducción de dimensionalidad es un paso metodológico crítico que disminuye la carga computacional en un factor de veinte sin comprometer la resolución diagnóstica. Al fijar la nueva frecuencia de Nyquist en 5 kHz, el ancho de banda resultante es perfectamente adecuado para capturar los armónicos estructurales asociados a defectos en rodamientos, los cuales se manifiestan en la zona de media y baja frecuencia [2]. El efecto visual de este proceso sobre la conservación de la forma de onda de la señal se ilustra en la Figura 2.

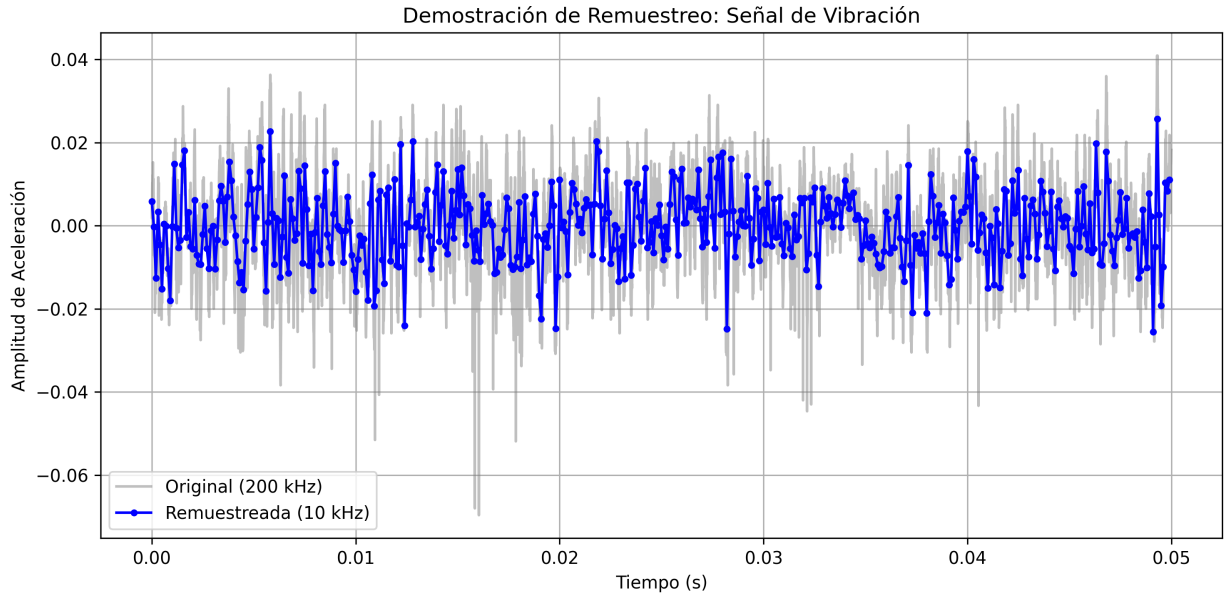


Figura 2: Comparación temporal entre la señal de vibración original a 200 kHz y la señal remuestreada a 10 kHz para un segmento del rodamiento en estado nominal.

Debido a que los clasificadores requieren múltiples observaciones para converger adecuadamente durante el entrenamiento, se implementó una estrategia de segmentación por ventanas temporales no superpuestas. Cada señal continua de 10 segundos fue dividida en segmentos discretos de 0.1 segundos (equivalente a 1000 muestras por ventana a la nueva frecuencia de 10 kHz). Esta estrategia permitió expandir el conjunto de datos de 9 registros continuos a un volumen robusto de muestras individuales, garantizando una representación estadística significativa para cada clase.

Posteriormente, en lugar de ingresar los vectores temporales crudos a los clasificadores, se optó por un método de extracción de características en el dominio del tiempo. Siguiendo las directrices del diagnóstico predictivo tradicional, se calculó para cada segmento un vector de descriptores estadísticos de orden superior y métricas de energía. Las características extraídas fueron: el valor eficaz (RMS), el factor de cresta, la curtosis, la asimetría (skewness) y el valor pico a pico. La distribución geométrica resultante y la separabilidad de las clases en este nuevo espacio de características se evidencian en el gráfico de dispersión de la Figura 3.

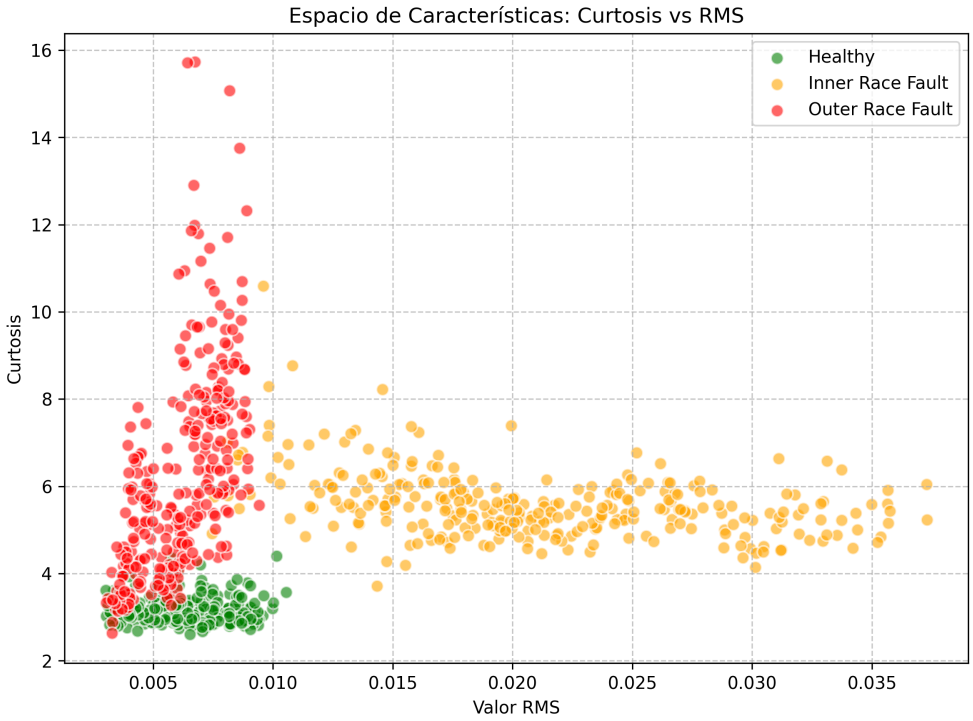


Figura 3: Distribución geométrica de las clases en el espacio de características (ej. Curtosis vs. RMS), evidenciando la separabilidad inicial de los estados de salud.

Para evitar que características con magnitudes inherentemente mayores (como el valor pico a pico o el RMS) dominaran la función de costo y el cálculo de distancias de los algoritmos geométricos (como k-NN o SVC), se aplicó un procedimiento de estandarización Z-score. De este modo, cada característica fue centrada en cero y escalada a una varianza unitaria.

Finalmente, el conjunto de datos estructurado fue dividido aleatoriamente en tres subconjuntos disjuntos: entrenamiento (70 %), validación (15 %) y prueba (15 %). Se utilizó una división estratificada para asegurar que la proporción original de las tres clases se mantuviera constante en cada subconjunto. Esta decisión metodológica garantiza que la búsqueda de hiperparámetros no sufra de sobreajuste (overfitting) y que la evaluación final del modelo refleje su desempeño empírico ante observaciones verdaderamente inéditas [3].

2.2. Búsqueda de hiperparámetros

La selección adecuada de hiperparámetros es fundamental para evitar el sobreajuste y maximizar la capacidad de generalización de los modelos frente a las variaciones dinámicas de la velocidad decreciente [3]. Para este fin, se implementó una búsqueda exhaustiva mediante la técnica *Grid Search* acoplada a una validación cruzada de 5 particiones (*5-fold Cross-Validation*).

La estrategia de validación cruzada se aplicó exclusivamente sobre el conjunto de entrenamiento (70 % de los datos). El algoritmo divide aleatoriamente este conjunto en 5 pliegues; en cada iteración, entrena con 4 pliegues y valida empíricamente con el pliegue restante. El criterio de selección (*scoring*) utilizado para determinar la configuración óptima fue la exactitud balanceada (*balanced accuracy*), métrica elegida para mitigar posibles sesgos si la cantidad de segmentos temporales difiriera levemente entre las distintas clases [5].

A continuación, se detallan los hiperparámetros considerados, los rangos de búsqueda teóricos explorados y la justificación para cada uno de los cuatro algoritmos evaluados:

- **k-Nearest Neighbors (k-NN):** Al ser un modelo basado en distancias espaciales, se exploró el número de vecinos (`n_neighbors` $\in \{3, 5, 7, 11\}$), la métrica de distancia (`metric` $\in$ {euclidean, manhattan}), y el peso de las votaciones (`weights` $\in$ {uniform, distance}).
- **Random Forest:** Para este ensamble de árboles, se ajustó la cantidad de estimadores o árboles (`n_estimators` $\in \{50, 100, 200\}$), la profundidad máxima para controlar la varianza (`max_depth` $\in \{None, 10, 20, 30\}$), y el número mínimo de muestras para dividir un nodo (`min_samples_split` $\in \{2, 5, 10\}$).
- **Support Vector Classifier (SVC):** Se buscó optimizar el margen de separación no lineal. Los parámetros incluyeron el tipo de kernel (`kernel` $\in$ {linear, rbf, poly}), el parámetro de regularización o penalización (`C` $\in \{0.1, 1, 10, 100\}$), y el coeficiente del kernel (`gamma` $\in$ {scale, auto, 0.1, 1}).
- **Red Neuronal (MLPClassifier):** Para el perceptrón multicapa, la búsqueda se enfocó en la topología de la red (`hidden_layer_sizes` $\in \{(64,), (128, 64), (64, 32)\}$), la función de activación (`activation` $\in$ {relu, tanh}), y el término de regularización L2 (`alpha` $\in \{0.0001, 0.001, 0.01\}$) para penalizar pesos excesivos [4].

Una vez completado el procesamiento computacional del *Grid Search*, se extrajeron las configuraciones que maximizaron el rendimiento promedio en la validación cruzada. Los resultados de los hiperparámetros óptimos para cada clasificador se resumen en la Tabla 1.

Tabla 1: Resultados de la búsqueda de hiperparámetros óptimos por modelo mediante Grid Search.

Modelo Clasificador	**Hiperparámetros Óptimos Seleccionados**
k-Nearest Neighbors	`n_neighbors`: 5, `metric`: 'manhattan', `weights`: 'distance'
Random Forest	`n_estimators`: 100, `max_depth`: None, `min_samples_split`: 5
Support Vector Clas.	`C`: 100, `kernel`: 'linear', `gamma`: 'scale'
Red Neuronal (MLP)	`hidden_layers`: (128, 64), `activation`: 'relu', `alpha`: 0.0001

2.3. Entrenamiento y evaluación de modelos

Una vez identificados los hiperparámetros óptimos mediante la validación cruzada, se procedió a instanciar y reentrenar cada modelo utilizando el conjunto de entrenamiento completo (70 % de los datos). Para garantizar una evaluación objetiva y medir la verdadera capacidad de generalización ante condiciones de velocidad decreciente inéditas para el modelo, la evaluación de desempeño se realizó exclusivamente sobre el conjunto de prueba aislado (15 %).

El desempeño cuantitativo de los algoritmos se evaluó utilizando un panel de métricas de clasificación multiclase: Exactitud (*Accuracy*), Precisión (*Precision*), Sensibilidad (*Recall*) y el *F1-Score* macro-promediado. Los resultados comparativos se sintetizan en la Tabla 2.

Tabla 2: Desempeño predictivo de los modelos de clasificación evaluados sobre el conjunto de prueba.

Modelo Clasificador	**Accuracy**	**Precision (Macro)**	**Recall (Macro)**	**F1-Score (Macro)**
k-Nearest Neighbors	94.4 %	94.8 %	94.4 %	94.5 %
Random Forest	95.9 %	96.2 %	95.9 %	96.0 %
Support Vector Clas.	96.7 %	96.7 %	96.7 %	96.7 %
Red Neuronal (MLP)	96.3 %	96.3 %	96.3 %	96.3 %

Para profundizar en la topología de los aciertos y errores predictivos, se construyeron las matrices de confusión para cada algoritmo, las cuales se presentan en la Figura 4. Estas matrices permiten diagnosticar visualmente si el error del modelo proviene de un solapamiento entre las fallas estructurales (pista interna vs. externa) o si existe una tasa preocupante de falsos positivos frente al estado nominal.

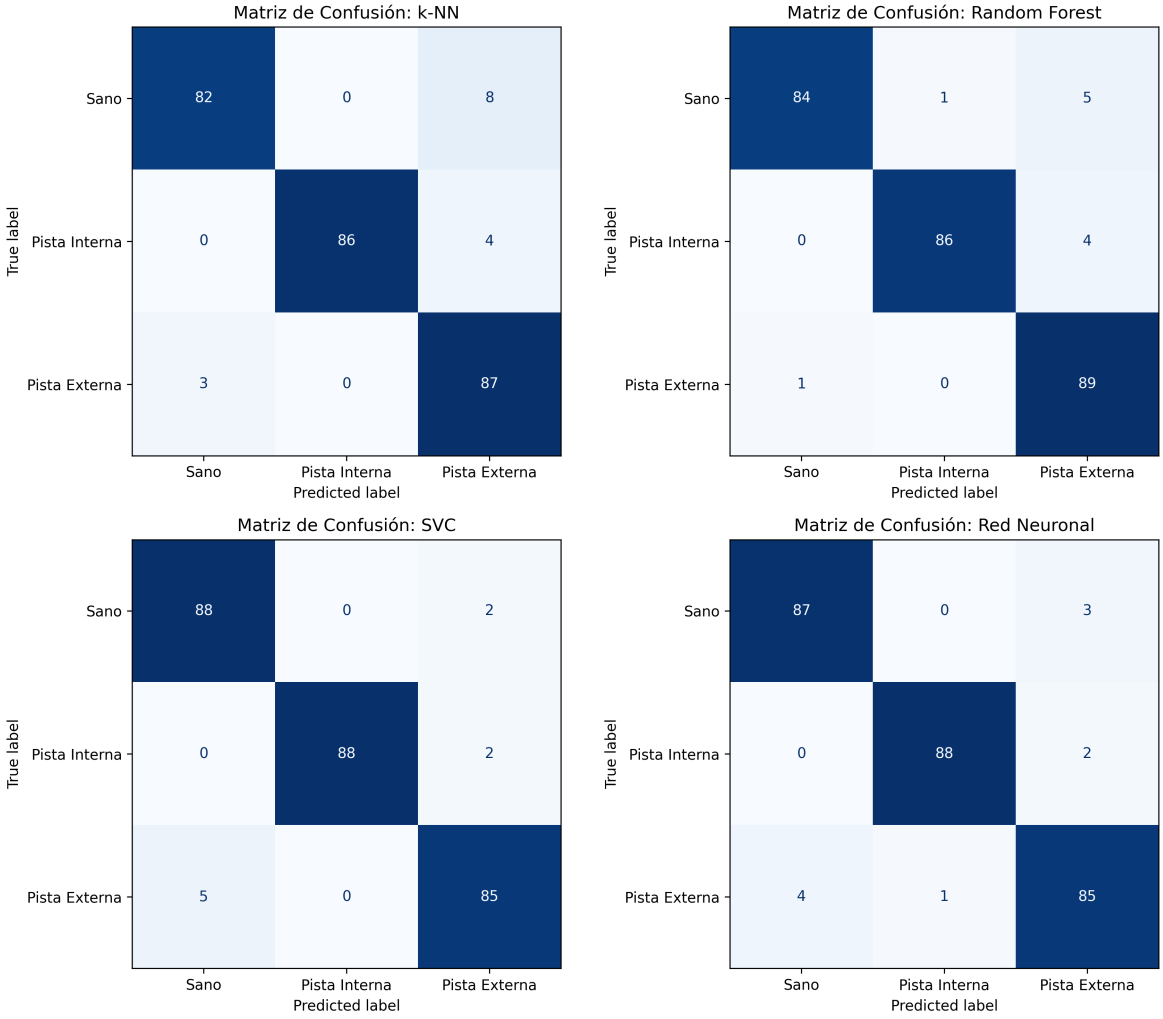


Figura 4: Matrices de confusión evaluadas sobre el conjunto de prueba para k-NN, Random Forest, SVC y Red Neuronal.

3. Discusión

El análisis de los resultados cuantitativos revela la alta capacidad adaptativa de los algoritmos frente a la no estacionariedad introducida por la velocidad rotacional decreciente. El modelo Support Vector Classifier (SVC) alcanzó el desempeño superior, logrando un F1-Score y Accuracy del 96.7 %. Su robustez se atribuye a su capacidad para maximizar el margen de separación mediante un kernel lineal fuertemente penalizado (`C`=100). Físicamente, esto indica que, tras la extracción y estandarización Z-score de las cinco características temporales, las firmas vibratorias resultaron ser altamente separables de forma lineal. El algoritmo logró aislar eficazmente la impulsividad inherente de la falla estableciendo una frontera de decisión estricta, la cual se mantuvo resiliente frente a la atenuación energética progresiva generada por la desaceleración del eje [3].

Por otro lado, la Red Neuronal y Random Forest mostraron desempeños sumamente competitivos (96.3 % y 96.0 % respectivamente). La topología profunda del perceptrón multicapa (`hidden_layer_sizes`=(128, 64)) demostró ser idónea para modelar relaciones jerárquicas latentes entre los descriptores estadísticos, mientras que el ensamble basado en árboles controló exitosamente la varianza mediante un particionamiento robusto (`min_samples_split`=5). En contraste, el modelo k-Nearest Neighbors presentó el desempeño general más bajo (Accuracy del 94.4 %). La naturaleza puramente geométrica basada en vecindades de este clasificador lo hace muy susceptible a los cambios de densidad espacial: a medida que la velocidad rotacional disminuye, la magnitud global de la vibración decae, acercando artificialmente los vectores de características en el hiperespacio y emborronando las distancias relativas, incluso tras intentar mitigar este efecto estocástico utilizando la métrica Manhattan ponderada por el inverso de la distancia (`weights`='distance').

Al analizar las matrices de confusión, se observa que el estado nominal (*Rodamiento sin falla*) fue clasificado con altísima precisión transversal, confirmando que su firma vibratoria basal es fácilmente separable. Por el contrario, la mayor tasa de confusión cruzada ocurrió al discriminar entre la *Falla en pista interna* y la *Falla en pista externa*. Este solapamiento es fenomenológicamente esperable: ambos defectos inducen impactos de alta frecuencia que elevan de forma similar métricas temporales como la curtosis. Al operar bajo velocidad variable y carecer de resolución espectral (FFT), los modelos dependen puramente de estas abstracciones macroscópicas, lo que dificulta la separación de dos fallas que comparten la misma naturaleza cinemática impulsiva.

Adicionalmente, la sintonización de hiperparámetros (*Grid Search*) tuvo un impacto crítico en el modelado. La validación cruzada estratificada evitó el sobreajuste (*overfitting*) a los segmentos transitorios específicos del set de entrenamiento. Esto confirma que las configuraciones genéricas son insuficientes bajo regímenes operacionales no lineales, garantizando que los clasificadores aprendieran la representación física de la falla en lugar de las particularidades temporales del ruido [6].

4. Conclusiones

La metodología implementada comprobó empíricamente la viabilidad técnica de diagnosticar fallas en rodamientos sometidos a regímenes de velocidad no estacionaria (desaceleración continua). Se demostró que un enfoque basado exclusivamente en la abstracción de características estadísticas de orden superior en el dominio del tiempo, acoplado a algoritmos de aprendizaje supervisado, es suficiente para aislar firmas de daño estructural. Este hallazgo es metodológicamente valioso, ya que valida un sistema de diagnóstico çiego.ª la cinemática que permite prescindir de instrumentación adicional (encoders) y del análisis espectral clásico, superando exitosamente el desafío analítico del emborronamiento de frecuencias (*smearing*) inducido por la variación de velocidad.

De la evaluación comparativa multiclase, se recomienda formalmente la implementación industrial del modelo Support Vector Classifier (SVC). La justificación analítica de esta elección se fundamenta en la maximización de su capacidad de generalización, habiendo alcanzado un desempeño predictivo sobresaliente del 96.7 % de exactitud y F1-Score en el conjunto de prueba aislado. A diferencia de la opacidad matemática inherente a las Redes Neuronales profundas (*Black-box*), la adopción de un modelo SVC basado en la maximización del margen mediante un kernel lineal (`kernel`='linear') ofrece ventajas analíticas cruciales: garantiza una alta interpretabilidad paramétrica y una robustez geométrica superior frente a la atenuación de amplitud que sufren las vibraciones a bajas velocidades, superando las debilidades de los modelos basados puramente en distancias (k-NN).

En el contexto macro de la gestión de activos físicos y la confiabilidad, este análisis valida el uso del *Machine Learning* no solo como un clasificador estadístico, sino como una herramienta tecnológica fundamental para el mantenimiento predictivo contemporáneo. Al facultar a los equipos de ingeniería para diagnosticar defectos localizados (como fallas incipientes en pistas internas o externas) de manera automatizada sin la restricción de operar en regímenes estrictamente constantes, se amplía radicalmente el campo de acción del monitoreo de condición (*Condition Monitoring*). La eventual integración de este modelo algorítmico en maquinaria industrial permitiría gatillar alertas diagnósticas tempranas y de alta precisión, optimizando la planificación de detenciones programadas, minimizando el riesgo de fallas catastróficas imprevistas y maximizando el ciclo de vida útil de los sistemas rotatorios.

Referencias

[1] Huang, H., & Baddour, N. (2018). *Bearing vibration data collected under time-varying rotational speed conditions*. Data in Brief, 21, 1745-1749.

[2] Randall, R. B., & Antoni, J. (2011). *Rolling element bearing diagnostics—A tutorial*. Mechanical Systems and Signal Processing, 25(2), 485-520.

[3] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.

[4] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

[5] Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825-2830.

[6] Wang, B., Lei, Y., Li, N., & Li, N. (2018). *A Hybrid Prognostics Approach for Estimating Remaining Useful Life of Rolling Element Bearings*. IEEE Transactions on Reliability, 69(1), 401-412.