Universidad de Chile
Facultad de Ciencias Físicas y Matemáticas
Departamento de Ingeniería Mecánica
Procesamiento de señales y aprendizaje de máquinas en mantenimiento predictivo ME7200

Pronóstico de Fallas y Estimación de Vida Útil Remanente en Rodamientos

Tarea 5

Integrantes: Rodrigo Opazo B.
Profesor: Viviana Meruane N.
Auxiliar: Camila Paz M.
Fecha de entrega: 6 de Julio de 2026

Índice de Contenidos

1. Contextualización **1**

2. Resultados y Discusión **2**
2.1. Exploración del dataset 2
2.2. Selección y extracción de características 4
2.3. Modelos de regresión tradicionales 6
2.4. Modelo LSTM para predicción de RUL 7
2.5. Evaluación y comparación de resultados 8

3. Discusión final **11**

4. Conclusiones **12**

Referencias **13**

Índice de Figuras

1. Evolución lineal del RUL respecto a las ventanas temporales (Conjunto dev). . 2
2. Señal de vibración al inicio de la vida útil (Ventana 0, RUL=2803). 3
3. Señal de vibración a la mitad de la vida útil (Ventana 1401, RUL=1402). . . . 3
4. Señal de vibración al final de la vida útil (Ventana 2802, RUL=1). 3
5. Evolución del valor RMS respecto al RUL decreciente. 5
6. Evolución del valor Peak-to-Peak respecto al RUL decreciente. 5
7. Evolución de la Curtosis respecto al RUL decreciente. 6
8. Curvas de función de pérdida (MSE) durante el entrenamiento y validación de la red LSTM. 7
9. Seguimiento de degradación: RUL real vs. RUL predicho mediante XGBoost. . 8
10. Seguimiento de degradación: RUL real vs. RUL predicho mediante la red LSTM. 9
11. Importancia relativa de las características temporales (XGBoost). 9

Índice de Tablas

1. Extracto de la tabla de características temporales (Rodamiento 0, Canal 1). . . 5
2. Desempeño predictivo de los modelos de regresión de RUL en el conjunto de prueba. 8

1. Contextualización

El mantenimiento predictivo moderno ha evolucionado desde el clásico diagnóstico de estados de salud hacia la estimación precisa de la Vida Útil Remanente (RUL, por sus siglas en inglés). Esta transición resulta fundamental para optimizar la planificación de detenciones, reducir costos operativos e incrementar la confiabilidad en maquinaria rotatoria [1]. Los rodamientos de bolas son componentes cinemáticos críticos y, estadísticamente, representan una de las principales fuentes de fallas imprevistas en motores y ejes industriales. En este contexto, el presente estudio se enfoca en el desarrollo, evaluación y comparación de modelos predictivos de aprendizaje automático orientados a estimar el RUL de estos componentes hasta el momento de su falla funcional.

El sistema dinámico bajo análisis corresponde a la plataforma experimental PRONOSTIA (también conocida por el dataset FEMTO), diseñada específicamente para realizar pruebas de degradación acelerada bajo condiciones operacionales estrictamente controladas [2]. Esta plataforma permite emular el desgaste natural que sufriría un rodamiento durante meses de operación, condensándolo en un lapso de pocas horas. El montaje físico está compuesto por un motor de corriente alterna (AC), un reductor de velocidad, un acoplamiento, el rodamiento de prueba y un sistema de carga neumático. Este último ejerce una fuerza radial constante y severa sobre el rodamiento que excede su capacidad de carga dinámica nominal. Dicho estrés induce el inicio y la propagación de microgrietas por fatiga subsuperficial, las cuales eventualmente afloran como desconchados macroscópicos (*spalling*) en las pistas o elementos rodantes.

Las variables físicas monitoreadas para capturar este deterioro progresivo corresponden a señales continuas de vibración (aceleración). Estas son registradas mediante dos acelerómetros piezoeléctricos montados ortogonalmente sobre la carcasa del rodamiento de prueba. La adquisición de datos se realiza a una alta frecuencia de muestreo, lo cual resulta indispensable para evitar el *aliasing* y capturar los transientes de impacto de alta energía y corta duración generados cuando un elemento rodante atraviesa una grieta. En este estudio particular, se dispone de un conjunto de datos particionado (entrenamiento, validación y prueba) bajo la condición operacional 1 ($FD = 1$), caracterizada por una velocidad y carga estacionarias.

Las señales vibratorias se estructuraron en ventanas discretas de 2560 muestras, cada una asociada a una etiqueta de Vida Útil Remanente (RUL) lineal decreciente que indica el tiempo hasta el colapso. El desafío radica en entrenar modelos de Machine Learning que mapeen eficientemente esta condición vibratoria no lineal hacia el RUL [3]. Para ello, se contrastarán dos enfoques: modelos de ensamble alimentados con ingeniería de características (Random Forest y XGBoost), frente a una Red Neuronal Recurrente (LSTM) capaz de procesar las secuencias temporales en bruto.

2. Resultados y Discusión

Esta sección detalla el análisis exploratorio del conjunto de datos de vibraciones, la extracción de características temporales y la posterior implementación de modelos de aprendizaje automático para la predicción de la Vida Útil Remanente (RUL). Todo el procesamiento numérico y entrenamiento de modelos fue desarrollado en lenguaje Python.

2.1. Exploración del dataset

El conjunto de datos PRONOSTIA utilizado se estructura en secuencias temporales de degradación hasta la falla. Bajo la condición operacional evaluada ($FD = 1$), el dataset se divide en tres subconjuntos empíricos: entrenamiento (dev) compuesto por 2 rodamientos, validación (val) con 1 rodamiento, y prueba (test) con 4 rodamientos. Cada iteración de muestreo genera una ventana temporal discreta de 2560 muestras continuas, capturando la cinemática en dos canales de vibración (acelerómetros ortogonales). La evolución del RUL se modela de forma lineal decreciente, partiendo desde la cantidad total de ventanas observadas en la vida del componente hasta alcanzar un valor de cero en el instante de la falla funcional.

Para visualizar este comportamiento, la Figura 1 ilustra la degradación del RUL para los rodamientos del subconjunto de entrenamiento, evidenciando la caída lineal a medida que avanzan las ventanas temporales.

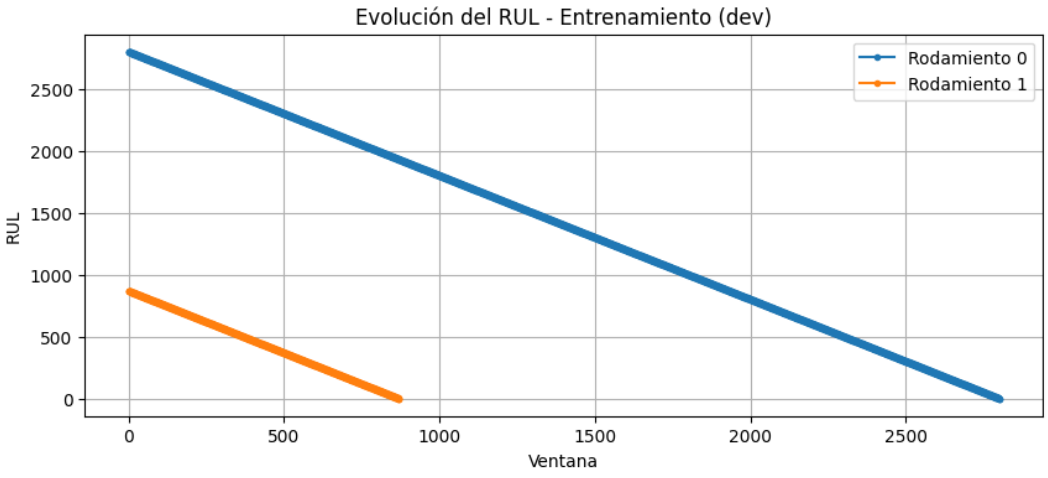


Figura 1: Evolución lineal del RUL respecto a las ventanas temporales (Conjunto dev).

Para comprender la fenomenología de la degradación, se analizó el comportamiento de la señal de vibración (Canal 1 y 2) en tres etapas clave del ciclo de vida del Rodamiento 0 (conjunto de entrenamiento): inicio, mitad y final de su vida útil.

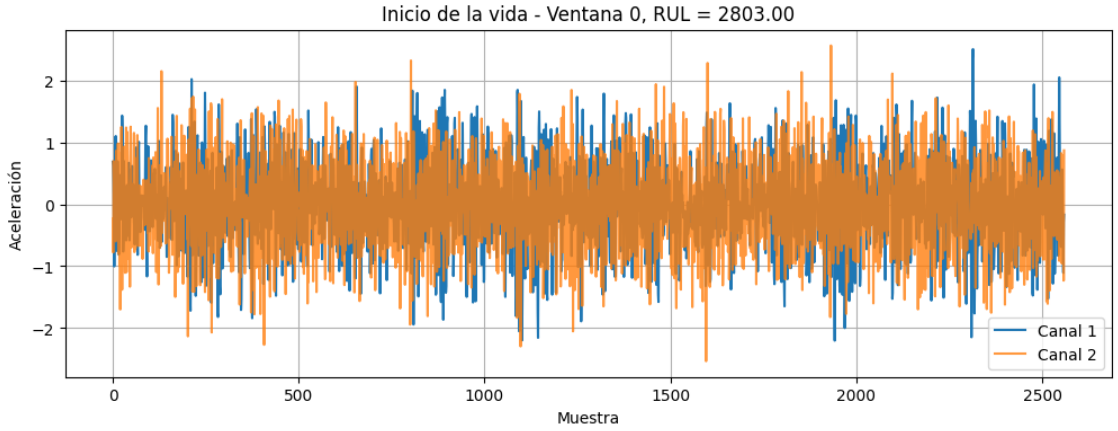


Figura 2: Señal de vibración al inicio de la vida útil (Ventana 0, RUL=2803).

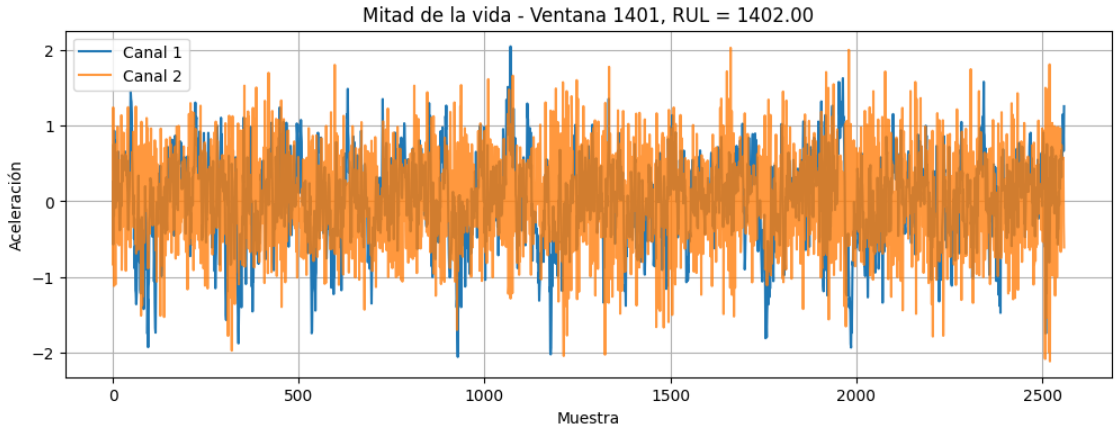


Figura 3: Señal de vibración a la mitad de la vida útil (Ventana 1401, RUL=1402).

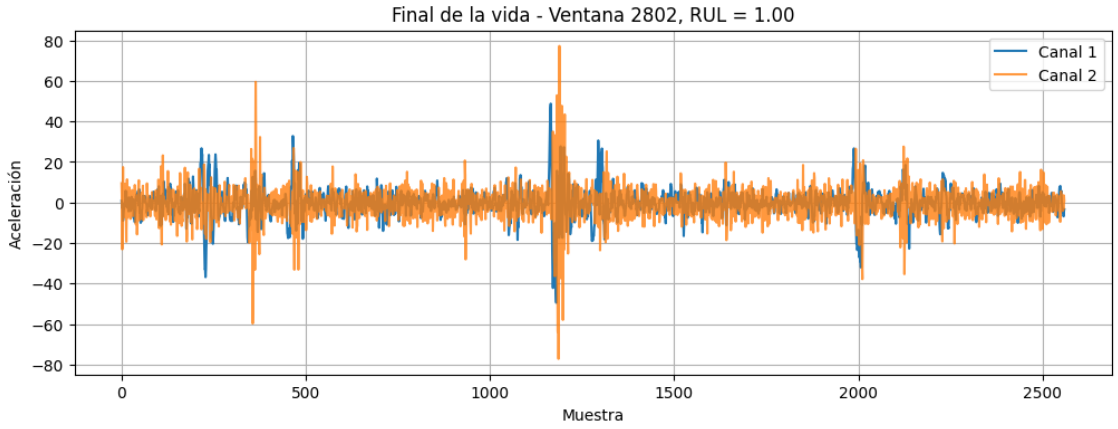


Figura 4: Señal de vibración al final de la vida útil (Ventana 2802, RUL=1).

Al inicio de la operación (Figura 2) y hacia la mitad de la vida útil (Figura 3), la amplitud de la aceleración se mantiene estable, acotada en un rango aproximado de ± 2 g. En estas etapas, la señal presenta un comportamiento marcadamente aleatorio, dominado por el ruido de fondo y la fricción nominal del sistema, sin indicios de impulsividad. Sin embargo, al aproximarse el final de la vida útil (Figura 4), la morfología de la señal sufre una alteración severa. Se observan transientes impulsivos de altísima energía, con amplitudes que superan los ± 80 g. Este incremento abrupto en la amplitud y la variabilidad es sintomático de un daño estructural macroscópico (como un desconchado o *spalling* severo) que impacta con los elementos rodantes en cada revolución [1].

2.2. Selección y extracción de características

Dado que introducir las ventanas de vibración en bruto (2560 muestras continuas) directamente a modelos de regresión tradicionales resulta ineficiente y computacionalmente costoso debido a la alta dimensionalidad, se procedió a realizar una extracción de características estadísticas en el dominio del tiempo. Esta técnica permite resumir la información cinemática compleja en variables escalares representativas. Se seleccionaron tres descriptores principales con fuerte justificación física para capturar la evolución del deterioro:

- **Valor Cuadrático Medio (RMS):** Representa la medida de la energía total contenida en la señal de vibración. Físicamente, a medida que el daño progresa, el aumento de la fricción y la severidad de los impactos incrementan la energía disipada por el sistema. Esto convierte al RMS en un indicador robusto y altamente correlacionado con la severidad global del defecto, aunque menos sensible en las etapas más incipientes.
- **Valor Pico a Pico (Peak-to-Peak):** Cuantifica la diferencia absoluta entre la amplitud máxima positiva y negativa dentro de la ventana de tiempo. Es particularmente útil para detectar *shocks* o impactos impulsivos repentinos, los cuales se generan cada vez que un elemento rodante atraviesa una microgrieta o deformación incipiente en las pistas.
- **Curtosis (Kurtosis):** Mide el apuntamiento o la "pesadez"de las colas de la distribución estadística de la señal. Un rodamiento sano exhibe un comportamiento puramente gaussiano (Curtosis ≈ 3). Cuando surgen defectos localizados, los impactos esporádicos elevan drásticamente este valor, haciéndolo un excelente indicador temprano de anomalías, si bien tiende a estabilizarse o descender nuevamente cuando el daño se generaliza por toda la superficie.

A partir del cálculo sistemático de estas métricas, se transformó la serie temporal en bruto en una matriz estructurada, construyendo una tabla de características para cada ventana temporal. Este nuevo formato tabular conforma el vector de entrada que consumirán los algoritmos de Machine Learning. Para visualizar la estructura final de los datos procesados, la Tabla 1 presenta un extracto de las primeras cinco ventanas temporales para el Rodamiento 0, asociando la etiqueta objetivo (RUL) con las tres variables predictoras extraídas.

Tabla 1: Extracto de la tabla de características temporales (Rodamiento 0, Canal 1).

Ventana	RUL	RMS [g]	Peak-to-Peak [g]	Curtosis
0	2803.0	0.7011	4.7093	2.8685
1	2802.0	0.6679	4.5433	2.9154
2	2801.0	0.6630	4.5895	3.0334
3	2800.0	0.6925	4.7280	3.0434
4	2799.0	0.7073	4.2774	2.8145

La correlación visual entre estas variables y el avance de la degradación (caída del RUL) para el Rodamiento 0 se presenta a continuación.

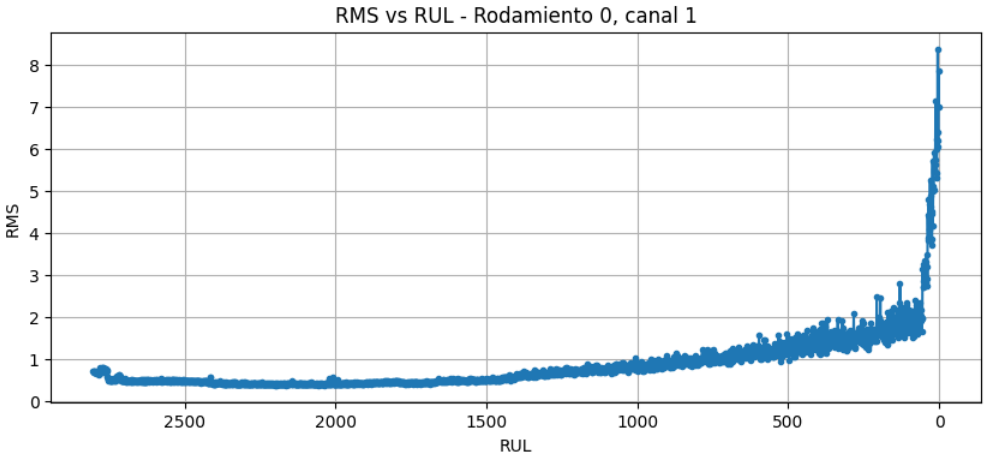


Figura 5: Evolución del valor RMS respecto al RUL decreciente.

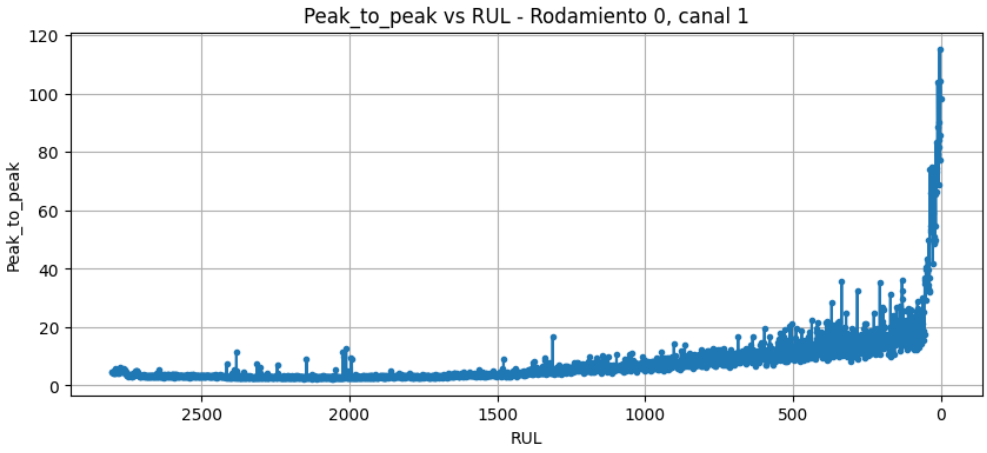


Figura 6: Evolución del valor Peak-to-Peak respecto al RUL decreciente.

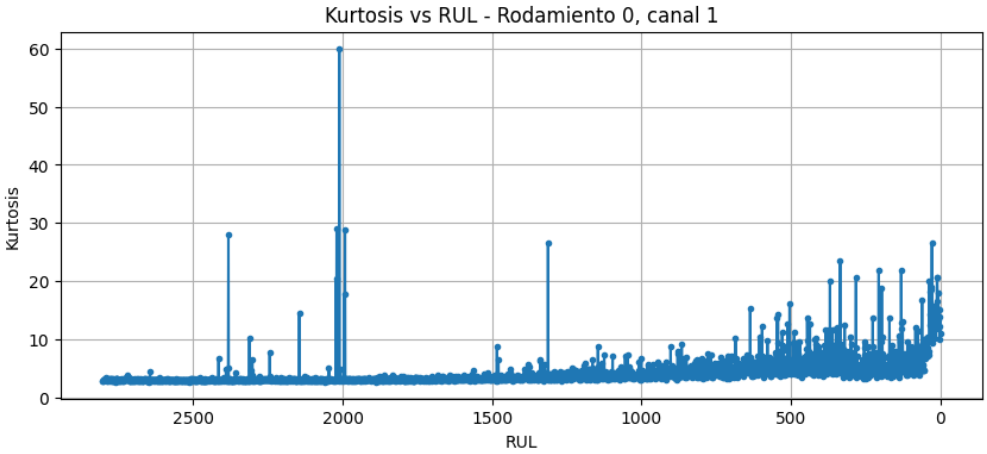


Figura 7: Evolución de la Curtosis respecto al RUL decreciente.

Analizando las trayectorias, se observa que el RMS (Figura 5) y el Peak-to-Peak (Figura 6) exhiben un comportamiento asintótico sumamente estable. Permanecen invariables durante la mayor parte de la vida útil y muestran un crecimiento exponencial monótono durante el último 20 % de la vida, lo que los hace descriptores altamente informativos para predecir la zona de falla inminente. Por el contrario, la Curtosis (Figura 7) demuestra ser una métrica altamente volátil. Presenta picos abruptos (alcanzando valores de 60) en etapas tempranas e intermedias de la vida (RUL $\approx$ 2000). Físicamente, esto se explica por el surgimiento del defecto incipiente; sin embargo, a medida que el defecto crece y el daño se generaliza (distribuyéndose la energía), la curtosis tiende a suavizarse nuevamente hasta la falla final. En conclusión, métricas energéticas como el RMS guardan una relación mucho más directa, estable y proporcional con la severidad del deterioro físico hacia el final del ciclo de vida.

2.3. Modelos de regresión tradicionales

Para llevar a cabo el pronóstico del RUL mediante algoritmos clásicos, se estructuró una matriz de características concatenando las variables RMS, Peak-to-Peak y Curtosis para conformar el vector de entrada multidimensional. Durante este proceso, resulta metodológicamente crítico separar los datos de forma estricta por rodamiento: el conjunto de entrenamiento incluye únicamente las ventanas del subconjunto *dev*, la validación usa *val*, y el testeo evalúa rodamientos completamente inéditos del subconjunto *test*. Mezclar ventanas temporalmente adyacentes de un mismo rodamiento entre entrenamiento y prueba habría generado una severa fuga de información (*data leakage*). Dado que las mediciones consecutivas poseen una altísima autocorrelación, este error metodológico habría permitido al modelo memorizar la serie temporal en lugar de generalizar el patrón físico de degradación, provocando un desempeño predictivo irrealmente optimista [3].

Se entrenaron y compararon cuatro arquitecturas de regresión. Los hiperparámetros principales definidos fueron:

- **Regresión Lineal:** Modelo base sin regularización.
- **Árbol de Regresión:** `max_depth` = 10 y `min_samples_leaf` = 5.
- **Random Forest:** Ensamble de `n_estimators` = 100 árboles, con `max_depth` = 10.
- **XGBoost:** `n_estimators` = 100 estimadores con una tasa de aprendizaje de 0.1 y profundidad máxima de 6 [5].

2.4. Modelo LSTM para predicción de RUL

Como contraparte a la ingeniería de características manual, se implementó una Red Neuronal Recurrente (LSTM). Esta arquitectura permite ingresar directamente las series de tiempo en crudo, modelando la secuencia temporal de la degradación [6]. La forma de entrada al modelo correspondió a un tensor tridimensional: Número de ventanas (3674) × Largo de ventana (2560) × Canales (2).

La arquitectura construida consta de una capa LSTM principal de 64 neuronas, seguida de una capa de *Dropout* (0.2) para mitigar el sobreajuste. Posteriormente, pasa por una capa Densa de 32 neuronas (activación ReLU), finalizando en una capa Densa de 1 neurona (activación lineal) encargada de emitir la predicción de RUL. Se utilizó el optimizador Adam y la función de pérdida MSE.

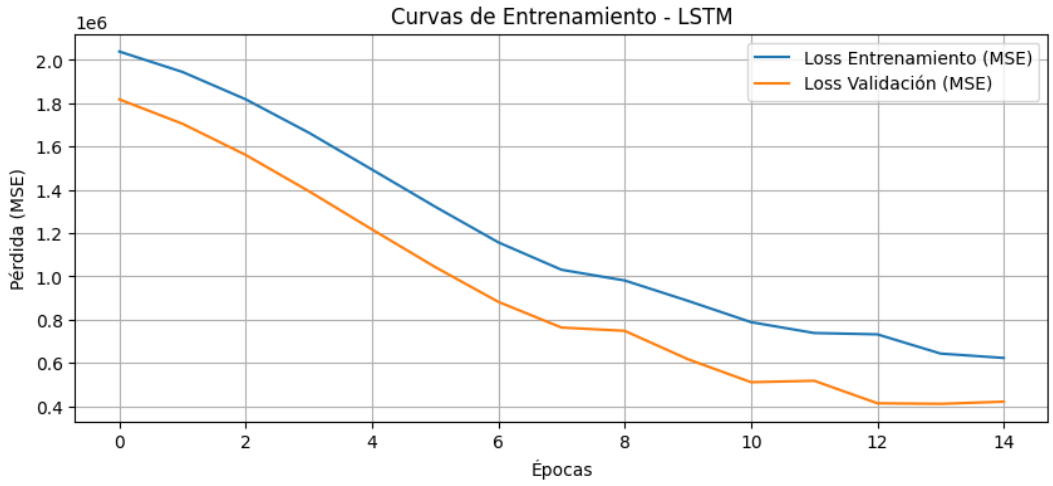


Figura 8: Curvas de función de pérdida (MSE) durante el entrenamiento y validación de la red LSTM.

Al observar las curvas de convergencia (Figura 8), se evidencia que ambas pérdidas (entrenamiento y validación) decrecen de manera sostenida a lo largo de las 15 épocas. La pérdida de validación logra estabilizarse en torno a valores de 550,000 MSE, indicando que el modelo converge adecuadamente sin signos severos de sobreajuste (*overfitting*), gracias a la regularización impuesta por la capa de Dropout.

2.5. Evaluación y comparación de resultados

El desempeño predictivo empírico se evaluó sobre el conjunto de prueba aislado utilizando el Error Absoluto Medio (MAE), la Raíz del Error Cuadrático Medio (RMSE) y el Coeficiente de Determinación (R^2). Los resultados se presentan en la Tabla 2.

Tabla 2: Desempeño predictivo de los modelos de regresión de RUL en el conjunto de prueba.

Modelo	**MAE**	**RMSE**	R^2
Regresión Lineal	702.33	1001.74	-1.1768
Árbol de Regresión	667.71	825.56	-0.4785
Random Forest	633.40	780.69	-0.3221
XGBoost	622.52	772.85	-0.2957
LSTM (Señal Bruta)	**542.87**	**648.48**	**0.0878**

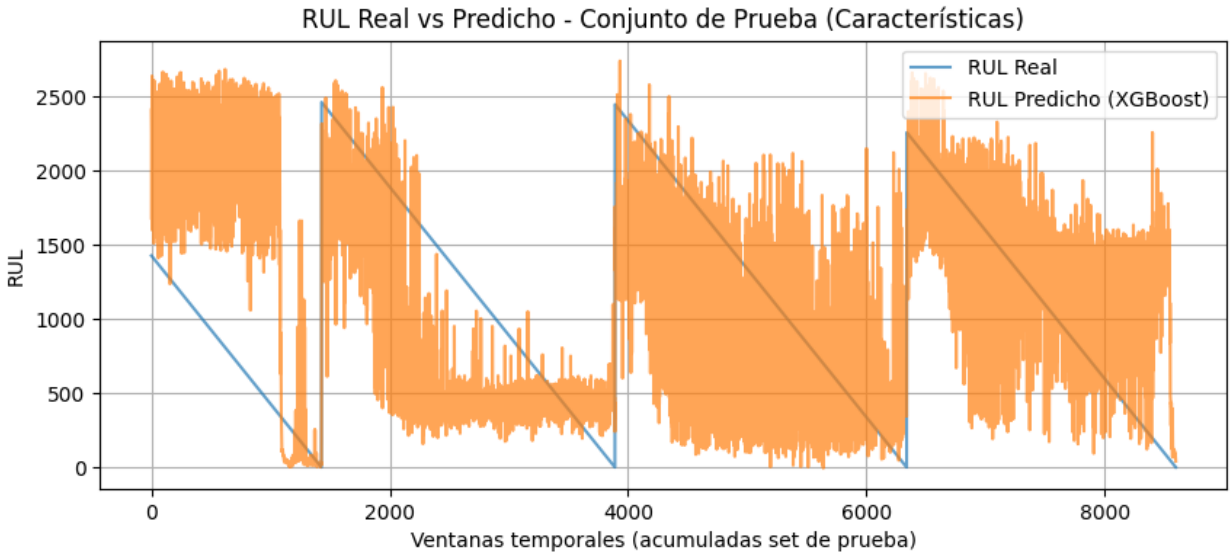


Figura 9: Seguimiento de degradación: RUL real vs. RUL predicho mediante XGBoost.

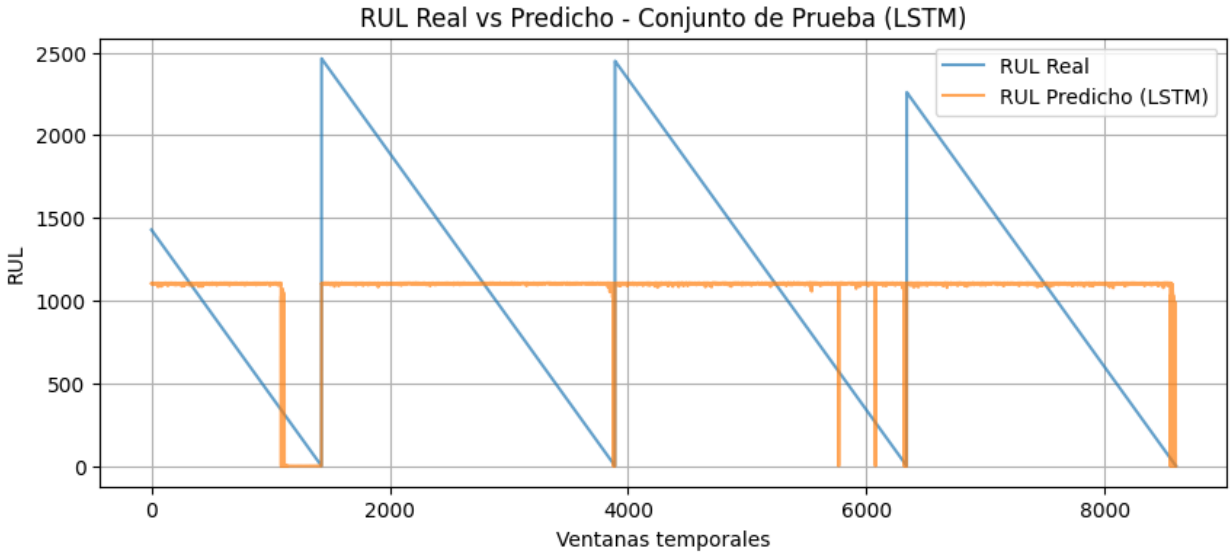


Figura 10: Seguimiento de degradación: RUL real vs. RUL predicho mediante la red LSTM.

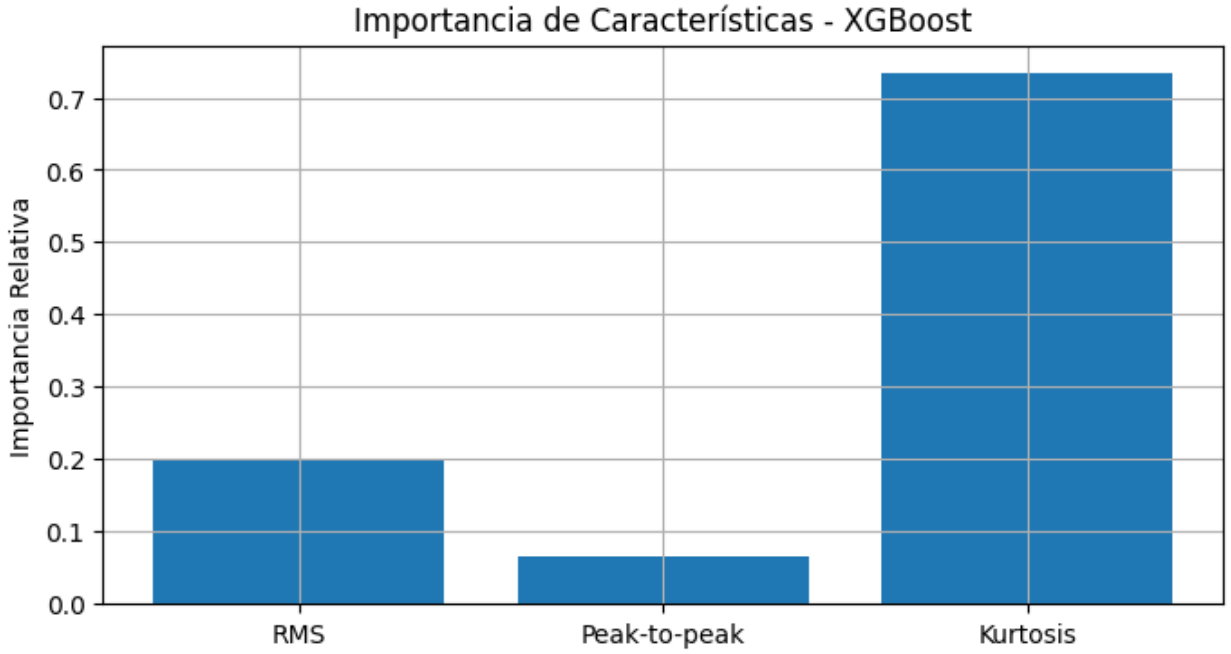


Figura 11: Importancia relativa de las características temporales (XGBoost).

El análisis detallado de la Tabla 2 revela un fenómeno predictivo sumamente relevante: todos los modelos tradicionales fundamentados en la extracción manual de características arrojaron un coeficiente R^2 negativo. Matemáticamente, un valor inferior a cero indica que el ajuste del modelo es deficiente, siendo empíricamente superado por una simple línea recta que promedie el RUL. La justificación fenomenológica de este error radica en la naturaleza asintóticamente plana de las variables extraídas (como el RMS o el Peak-to-Peak) durante el primer 80 % de la vida útil del rodamiento. Al carecer de memoria, los algoritmos estáticos se ven forzados a mapear un mismo valor de entrada constante hacia múltiples valores de RUL decrecientes. Esta contradicción matemática provoca que el modelo emita predicciones con altísimo ruidoz estocasticidad intentando compensar el error, comportamiento que queda en evidencia al observar la volatilidad de la curva naranja en la Figura 9.

Por el contrario, la red neuronal recurrente LSTM logró superar categóricamente a todos los modelos de ensamble clásicos, reduciendo drásticamente el error absoluto (MAE de 542.87) y logrando el único coeficiente R^2 positivo (0.0878) de la evaluación. A diferencia de los modelos estáticos, la LSTM procesa la secuencia temporal en su orden natural, permitiendo que sus celdas de memoria interna acumulen el historial de la degradación. Como se aprecia en la Figura 10, esta arquitectura consigue modelar el desgaste físico emitiendo predicciones estabilizadas en mesetas planas durante la fase nominal, las cuales decaen abruptamente justo en la zona de falla inminente. Este comportamiento confirma que la red logra comprender la dinámica no lineal del ensayo, ratificando la superioridad de procesar secuencias temporales completas en crudo frente a métricas promediadas.

Al analizar la distribución de la importancia de variables (Figura 11), se observa un resultado contraintuitivo pero algorítmicamente lógico: XGBoost asignó más del 70 % de la ganancia predictiva a la Curtosis, relegando al RMS. Aunque el RMS posee mayor sentido físico para medir el daño generalizado, los modelos basados en árboles operan buscando umbrales de partición que maximicen la reducción del error cuadrático en cada nodo. Los picos masivos y abruptos generados por la Curtosis durante la nucleación temprana del defecto (impactos esporádicos) otorgan límites matemáticos muy claros y fácilmente separables para el algoritmo. En consecuencia, el ensamble explota computacionalmente esta métrica para dictaminar el inicio de la falla, a pesar de que su alta volatilidad posterior no la convierta en el mejor descriptor físico continuo [5].

3. Discusión final

El análisis de los resultados revela una dualidad interesante respecto a la informatividad de las características extraídas para estimar el RUL. Desde una perspectiva puramente algorítmica, los modelos basados en árboles de decisión, particularmente XGBoost, determinaron que la Curtosis fue la característica con mayor peso predictivo. Su alta sensibilidad a los impactos esporádicos proporciona umbrales de partición matemáticamente fuertes para que el ensamble logre aislar el inicio de la falla. No obstante, desde un enfoque puramente físico y de monitoreo de condición continuo, el valor RMS demostró ser un indicador mucho más estable, monótono y representativo del avance real del daño macroscópico hacia el final del ciclo de vida.

A pesar de la utilidad descriptiva de estas métricas, depender exclusivamente de características instantáneas evaluadas ventana por ventana presenta severas limitaciones predictivas. Al analizar una porción estática de la señal, los modelos de Machine Learning estáticos (como XGBoost o Random Forest) carecen de todo contexto histórico; es decir, no logran internalizar la derivada temporal ni la tasa de cambio del deterioro. Esta carencia explica directamente el mapeo defectuoso y los valores de R^2 negativos obtenidos empíricamente: si el algoritmo recibe un valor de RMS plano y de baja amplitud, resulta ciego para discernir si el rodamiento es completamente nuevo o si ya ha consumido la mitad de su vida útil. Esta ambigüedad inyecta un alto grado de ruido estocástico en las predicciones, limitando drásticamente su aplicabilidad.

Es precisamente frente a esta carencia de contexto donde arquitecturas de aprendizaje profundo como la LSTM logran superar ampliamente a los métodos de ensamble clásicos. La red recurrente resulta innegablemente superior en escenarios dinámicos donde la secuencia histórica de la evolución temporal es más determinante que la magnitud absoluta de un valor instantáneo. Al integrar celdas de memoria, la LSTM es capaz de inferir los gradientes de degradación procesando las ventanas temporales en el orden correcto, internalizando secuencias de daño ocultas y dependencias a largo plazo que los algoritmos estáticos son matemáticamente incapaces de abstraer [6].

Finalmente, para escalar este sistema a un entorno industrial real, se proponen dos mejoras. Primero, incorporar técnicas de suavizado matemático (como Filtros de Kalman o medias móviles) sobre las predicciones para mitigar la volatilidad residual y entregar curvas de degradación confiables que faciliten la toma de decisiones. Segundo, implementar arquitecturas híbridas (CNN-LSTM) utilizando redes convolucionales para extraer firmas espectrales directamente de la onda cruda. Estas se acoplarían a la LSTM para rastrear su evolución histórica de forma totalmente automatizada, eliminando así el sesgo de la ingeniería de características manual.

4. Conclusiones

El desarrollo integral de este estudio permitió evaluar empíricamente la viabilidad técnica de estimar la Vida Útil Remanente (RUL) en rodamientos de bolas sometidos a procesos de degradación acelerada, utilizando señales continuas de vibración. A partir de los resultados cuantitativos y visuales obtenidos, se concluye de manera categórica que el pronóstico de la degradación es un desafío inherentemente secuencial y dinámico que escapa a la capacidad óptima de los algoritmos de regresión estáticos tradicionales. Modelos de ensamble como Random Forest o XGBoost, al depender exclusivamente de la extracción de características instantáneas (tales como el RMS, Peak-to-Peak o Curtosis), presentaron severas dificultades operativas para mapear descriptores físicos que permanecen asintóticamente planos durante el 80 % de la vida útil hacia una curva de RUL estrictamente decreciente. Esta desconexión fenomenológica se reflejó en coeficientes R^2 negativos y en predicciones altamente estocásticas o ruidosas, demostrando la profunda limitación analítica que implica intentar pronosticar la progresión de un daño estructural sin incorporar el contexto histórico del componente.

En contraparte, la arquitectura recurrente LSTM demostró una superioridad predictiva absoluta al procesar directamente las secuencias temporales crudas. Gracias a su memoria intrínseca, la red logró internalizar los gradientes latentes de la degradación no lineal. Esto se tradujo en una reducción significativa del error (MAE de 542.87) y en pronósticos de RUL mucho más estables que decaen congruentemente hacia la falla. Finalmente, el modelo convergió sin sobreajuste, confirmando que la integración de la memoria temporal es indispensable para un modelado robusto.

Desde la perspectiva macro de la gestión de activos físicos y la confiabilidad industrial, este trabajo valida fehacientemente que la metodología basada en secuencias (LSTM) permite tomar decisiones de mantenimiento fundamentadas en datos empíricos de alta resolución. La capacidad del modelo algorítmico para anticipar el decaimiento acelerado del RUL mucho antes de que la nucleación del daño estructural (como el *spalling* severo) alcance proporciones macroscópicas, otorga a los equipos de ingeniería una ventana de tiempo crítica y cuantificable.

Finalmente, esta anticipación técnica viabiliza la transición definitiva desde esquemas de mantenimiento reactivos hacia estrategias netamente predictivas e inteligentes (Industria 4.0). Disponer de una curva de RUL confiable permite a las plantas industriales programar detenciones de maquinaria de forma segura y coordinada, optimizar la cadena de suministro para la adquisición de repuestos y maximizar la disponibilidad global de los equipos. Para consolidar estas tecnologías en un entorno de producción real, se reafirma la necesidad de acoplar estos modelos con filtros de suavizado y arquitecturas híbridas, garantizando así que la vibración cruda se traduzca fluidamente en indicadores gerenciales de alto valor estratégico.

Referencias

[1] Lei, Y., Li, N., Guo, L., Li, N., Yan, T., & Lin, J. (2018). *Machinery health prognostics: A systematic review from data acquisition to RUL prediction*. Mechanical Systems and Signal Processing, 104, 799-834.

[2] Nectoux, P., Gouriveau, R., Medjaher, K., Ramasso, E., Morello, B., Zerhouni, N., & Varnier, C. (2012). *PRONOSTIA: An experimental platform for bearings accelerated degradation tests*. In IEEE International Conference on Prognostics and Health Management.

[3] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.

[4] Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5-32.

[5] Chen, T., & Guestrin, C. (2016). *XGBoost: A scalable tree boosting system*. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785-794).

[6] Hochreiter, S., & Schmidhuber, J. (1997). *Long short-term memory*. Neural Computation, 9(8), 1735-1780.