Universidad de Chile
Facultad de Ciencias Físicas y Matemáticas
Departamento de Ingeniería Mecánica
Procesamiento de señales y aprendizaje de máquinas en mantenimiento predictivo ME7200

Detección de Anomalías

Tarea 3

Integrantes: Rodrigo Opazo B.
Profesor: Viviana Meruane N.
Auxiliar: Camila Paz M.
Fecha de entrega: 8 de Junio de 2026

Índice de Contenidos

1. Contextualización **1**

2. Resultados y Discusión **2**
2.1. Estrategia 1: Análisis Exploratorio y Evolución Temporal de Parámetros Estadísticos 2
2.2. Implementación y Evaluación de Modelos de Detección de Anomalías . . . 7
2.3. Estrategia 2: Detección Espectral con Red Neuronal Autoencoder 8

3. Conclusiones **10**

Referencias **11**

Índice de Figuras

1. Trayectoria paramétrica de la Curtosis para los canales horizontal y vertical a lo largo de la vida operativa del rodamiento. 2
2. Evolución temporal del Factor de Cresta, evidenciando el incremento impulsivo inicial y su posterior saturación por degradación severa. 3
3. Trayectoria temporal de la Asimetría (Skewness), denotando la pérdida de simetría estadística debido a la direccionalidad del impacto de falla. 4
4. Trayectoria paramétrica del Valor RMS. Se observa una transición exponencial a partir del minuto 29 asociada a la degradación macroscópica. 4
5. Evolución temporal de la Energía total de la señal vibratoria, demostrando la acumulación disipativa en los últimos minutos de operación. 5
6. Desviación Estándar de las aceleraciones en el dominio del tiempo. 5
7. Comportamiento de la amplitud máxima absoluta (envolvente) de la señal. . . 6
8. Evolución del Valor Pico a Pico, confirmando la expansión del margen dinámico de vibración ante el daño estructural severo. 6
9. Comparación de funciones de decisión para los modelos de anomalía. Se visualiza la inestabilidad del OCSVM (minuto 1) y el cruce del umbral de Mahalanobis e I-Forest (minutos 16 y 15), seguidos de un quiebre geométrico persistente en el minuto 29. 8
10. Error de reconstrucción topológica del modelo Autoencoder alimentado por vectores espectrales (FFT). El inicio formal de la degradación queda enmarcado en el minuto 16 tras cruzar el umbral estadístico. 9

1. Contextualización

El mantenimiento predictivo fundamentado en el análisis de señales de vibración constituye un mecanismo analítico robusto para evaluar la integridad estructural y diagnosticar fallas incipientes en componentes mecánicos de rotación [2]. En el presente estudio, el sistema dinámico a evaluar corresponde a un rodamiento de rodillos modelo LDK UER204. Los datos utilizados provienen del *XJTU-SY Bearing Dataset* [1], el cual documenta ensayos acelerados de degradación (*run-to-failure*) obtenidos en un banco de pruebas especializado. Dicho sistema experimental está compuesto por un motor de inducción de corriente alterna, un controlador de velocidad y un sistema de carga hidráulica diseñado para aplicar fuerzas radiales controladas sobre la carcasa del componente ensayado.

Específicamente, el análisis se circunscribe al experimento denominado *Bearing 2_4*. Este ensayo corresponde a una condición de operación exigente y constante, caracterizada por una velocidad de rotación de 2250 rpm (37.5 Hz) y una carga radial aplicada de 11 kN. Para capturar la cinemática del desgaste, las variables medidas corresponden a las señales de aceleración vibratoria. Estas fueron registradas mediante el uso de dos acelerómetros (modelo PCB 352C33) posicionados ortogonalmente a 90° sobre la carcasa del rodamiento, permitiendo capturar de forma simultánea los canales de vibración en el eje horizontal y en el eje vertical.

El subconjunto de datos extraído para este experimento se estructura en 42 archivos en formato CSV. Es imperativo definir analíticamente qué representa cada uno de estos archivos dentro del dominio temporal del ensayo: cada documento constituye una ventana de observación discreta tomada a intervalos regulares de 1 minuto. Durante cada evento de muestreo, el sistema de adquisición registró 1.28 segundos continuos de señal operando a una frecuencia de muestreo de 25.6 kHz. En consecuencia, cada archivo encapsula exactamente 32,768 muestras empíricas por canal, proporcionando una representación estocástica de alta resolución de la dinámica del rodamiento en ese instante de vida particular.

El objetivo central del análisis es determinar, a través de modelos matemáticos y algoritmos de detección de anomalías [3], el límite temporal exacto en el que el rodamiento transiciona de su régimen de operación nominal a un comportamiento anómalo que evidencia el inicio de la degradación (falla en la pista exterior). Para abordar este problema, se implementarán y compararán dos estrategias analíticas disjuntas. La primera se basa en la extracción de parámetros estadísticos en el dominio del tiempo acoplados a modelos de detección de novedades (*One-Class SVM, Isolation Forest*, entre otros) [4, 6]. La segunda estrategia opera en el dominio espectral, utilizando la Transformada Rápida de Fourier (FFT) para alimentar un modelo de red neuronal tipo *Autoencoder* [5], permitiendo utilizar el error de reconstrucción topológica como umbral de detección de la anomalía.

2. Resultados y Discusión

2.1. Estrategia 1: Análisis Exploratorio y Evolución Temporal de Parámetros Estadísticos

El diagnóstico por condición y la detección de novedades en componentes rotatorios requiere caracterizar la trayectoria temporal de las propiedades estadísticas de la señal de vibración [2]. Al evaluar el experimento *Bearing 2_4*, se observa un comportamiento estacionario inicial que se extiende desde el minuto 1 hasta aproximadamente el minuto 28. Durante este intervalo, las fuerzas disipativas y mecánicas operan bajo un régimen de equilibrio estocástico, lo que representa la condición nominal de operación del rodamiento. No obstante, a partir del minuto 29, el sistema experimenta una transición cinemática irreversible debido a la aparición de un defecto localizado en la pista exterior (*outer race fault*), modificando la distribución de probabilidad de las amplitudes de aceleración.

Para aislar el inicio de la degradación, se analiza la evolución de la curtosis (Figura 1), métrica que cuantifica la impulsividad de la señal. En régimen nominal ($t < 28$ min), ambos canales fluctúan en torno a 3.0, comportamiento consistente con un ruido aleatorio gaussiano de fondo. En el minuto 29, el canal horizontal exhibe un incremento abrupto superando el valor de 6.0. Este fenómeno marca el instante exacto en que los elementos rodantes impactan la micro-picadura incipiente de la pista exterior, generando pulsos transitorios de alta amplitud. Posteriormente, la curtosis decae de forma progresiva; esto ocurre porque el daño se generaliza mediante desprendimiento continuo (*spalling*), lo que suaviza los impactos individuales y eleva la energía global de fondo, reduciendo así la impulsividad relativa de la señal.

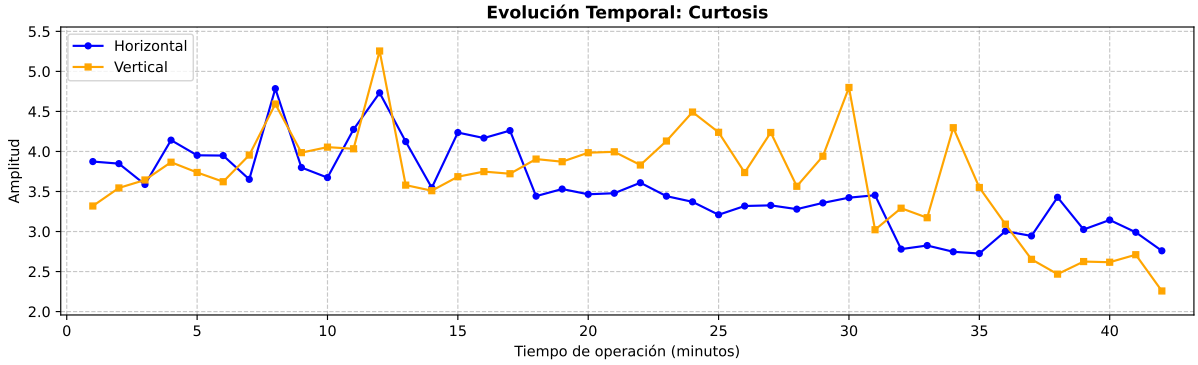


Figura 1: Trayectoria paramétrica de la Curtosis para los canales horizontal y vertical a lo largo de la vida operativa del rodamiento.

Una respuesta fenomenológica homóloga se aprecia en el factor de cresta, cuya trayectoria se detalla en la Figura 2. Matemáticamente, el factor de cresta se define como la razón entre el valor máximo absoluto y el valor eficaz (RMS) de la señal. Durante la fase de salud óptima del componente, este parámetro se mantiene estable en torno a un valor de 4.5, indicando una relación constante entre los picos de vibración y la energía media. Coincidiendo con la inflexión observada en la curtosis, el factor de cresta del canal horizontal experimenta un incremento agudo en el minuto 29, superando un umbral crítico de 6.5. Este incremento se justifica algebraicamente debido a que los primeros impactos de la falla elevan de forma inmediata el valor peak de la señal (X_{max}), mientras que la energía global acumulada (X_{rms}) varía marginalmente en dicha ventana de tiempo. El posterior decaimiento del factor de cresta confirma la transición hacia una falla generalizada, donde el incremento sostenido del denominador (RMS) atenúa el valor de la razón geométrica.

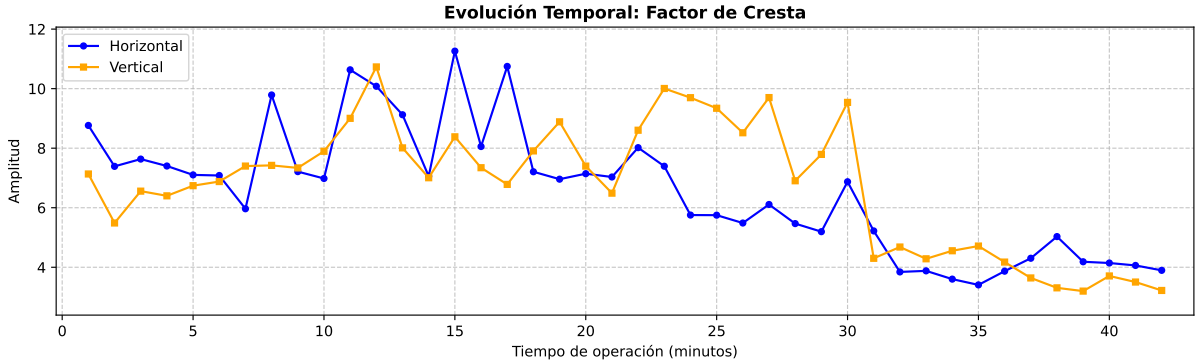


Figura 2: Evolución temporal del Factor de Cresta, evidenciando el incremento impulsivo inicial y su posterior saturación por degradación severa.

Complementando el análisis de la forma de la distribución, la Figura 3 ilustra la evolución de la asimetría (*skewness*), parámetro que representa el tercer momento estandarizado de la señal. Para un sistema tribológico en estado nominal, la asimetría oscila simétricamente en torno a cero, confirmando la naturaleza balanceada de las aceleraciones en ambos sentidos de los ejes ortogonales. Al desencadenarse la falla en la pista exterior, el canal horizontal sufre una severa desviación hacia valores negativos en el minuto 29, rompiendo la simetría de la densidad de probabilidad. Este comportamiento se asocia a la direccionalidad espacial del sensor respecto a la zona de carga hidráulica del banco de pruebas; los impactos inducidos por el defecto mecánico excitan el transductor predominantemente en una dirección del plano coordenado, induciendo una asimetría estructural que se estabiliza momentáneamente antes de la falla catastrófica final.

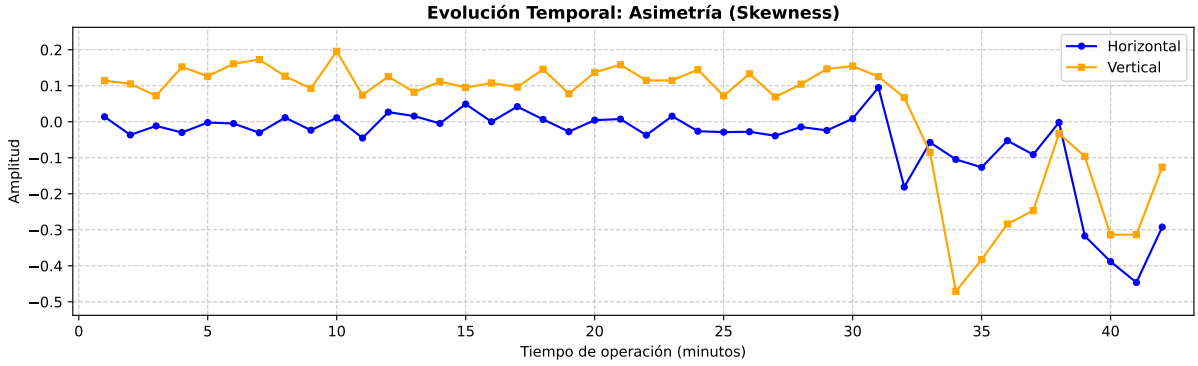


Figura 3: Trayectoria temporal de la Asimetría (Skewness), denotando la pérdida de simetría estadística debido a la direccionalidad del impacto de falla.

Habiendo caracterizado la alteración de la forma de la señal mediante los momentos de orden superior (curtosis y asimetría), el análisis topológico debe complementarse con las métricas de amplitud, dispersión y energía del sistema. La Figura 4 expone la evolución del valor eficaz (RMS), el cual representa la energía promedio de la señal de vibración y es el indicador estándar industrial para evaluar la severidad global de un defecto [2]. A diferencia de la curtosis, el RMS es insensible a impactos microscópicos tempranos; se mantiene estrictamente constante durante los primeros 28 minutos. Sin embargo, a partir del minuto 29, coincidiendo con la expansión volumétrica de la micro-picadura a un desprendimiento macroscópico continuo (*spalling*), el RMS experimenta un crecimiento exponencial, evidenciando que la energía de falla ha superado la capacidad de disipación mecánica del rodamiento.

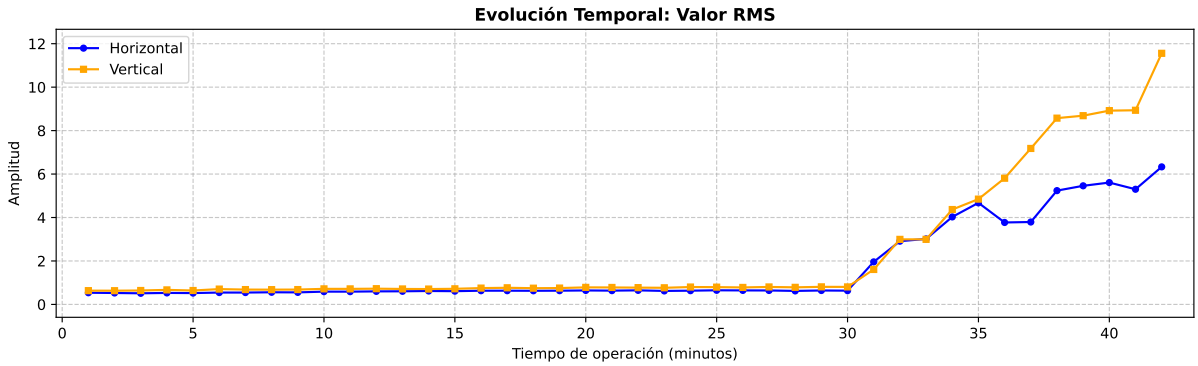


Figura 4: Trayectoria paramétrica del Valor RMS. Se observa una transición exponencial a partir del minuto 29 asociada a la degradación macroscópica.

Este comportamiento energético se corrobora de forma absoluta al evaluar el estimador algebraico directo de la Energía, ilustrado en la Figura 5. Al ser una sumatoria del cuadrado de las amplitudes $E = \sum x[n]^2$, esta métrica amplifica la varianza de los estados finales de vida del componente. La divergencia tardía pero monótonamente creciente de la energía confirma que, tras el inicio de la falla en la pista exterior, el área de contacto efectiva del rodamiento se reduce drásticamente, obligando al sistema a disipar la carga radial constante de 11 kN mediante calor y vibraciones de alta amplitud.

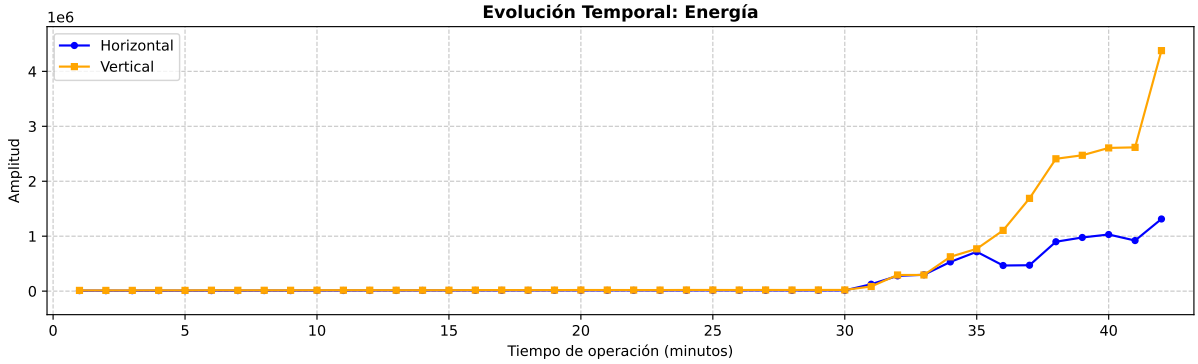


Figura 5: Evolución temporal de la Energía total de la señal vibratoria, demostrando la acumulación disipativa en los últimos minutos de operación.

Finalmente, para encapsular la cinemática completa del espacio de estado nominal y degradado, se evalúan la Desviación Estándar, el Máximo Absoluto y el Valor Pico a Pico (Figuras 6, 7 y 8). La topología de estas tres curvas exhibe una isomorfía casi perfecta con el RMS, dado que la desviación estándar de una señal con media cero es analíticamente equivalente a su valor eficaz. El crecimiento simultáneo de la envolvente máxima (Máximo Absoluto) y la amplitud total de la onda (Pico a Pico) en los últimos 13 minutos del ensayo ratifican que el daño no es puntual, sino que genera perturbaciones mecánicas de banda ancha de forma continua y sostenida [2].

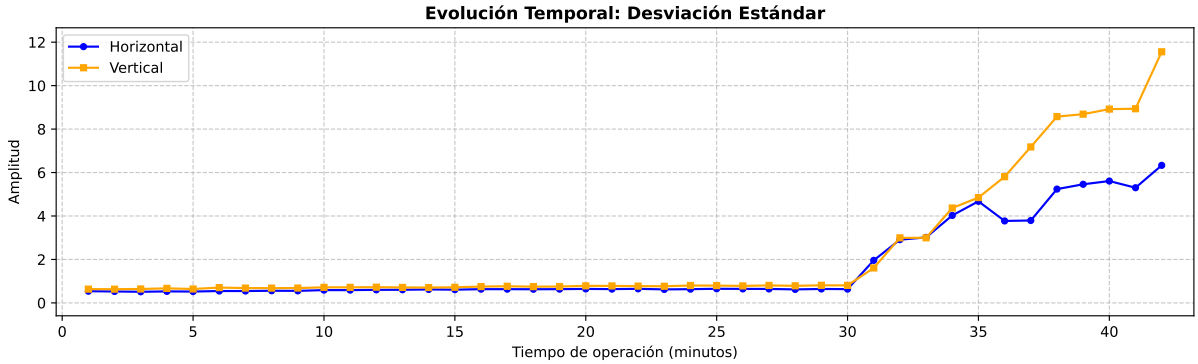


Figura 6: Desviación Estándar de las aceleraciones en el dominio del tiempo.

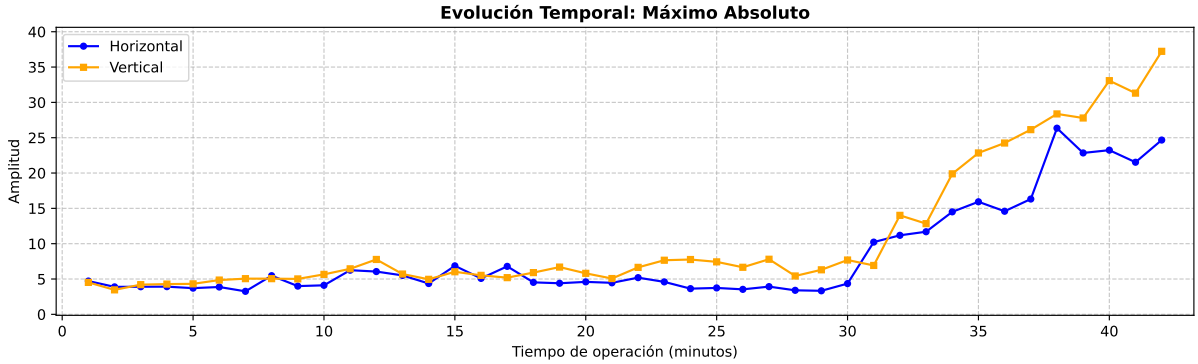


Figura 7: Comportamiento de la amplitud máxima absoluta (envolvente) de la señal.

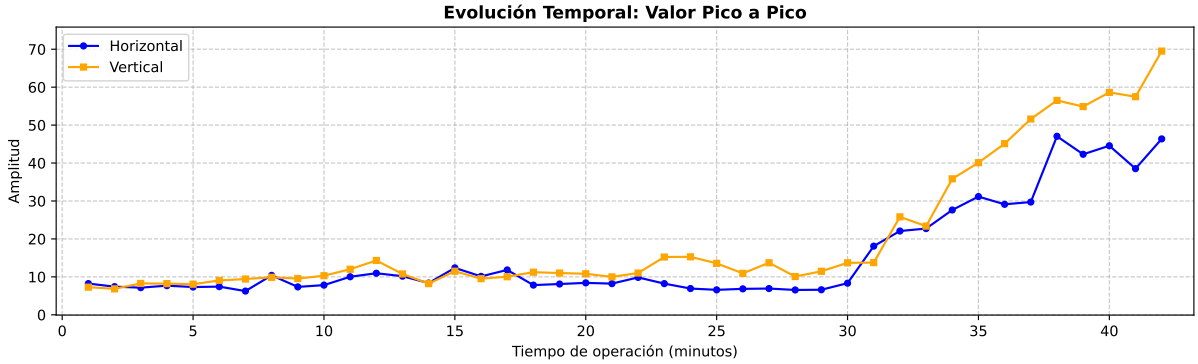


Figura 8: Evolución del Valor Pico a Pico, confirmando la expansión del margen dinámico de vibración ante el daño estructural severo.

2.2. Implementación y Evaluación de Modelos de Detección de Anomalías

Para determinar analíticamente el instante preciso en que el rodamiento abandona su condición de salud nominal, se implementó un esquema de aprendizaje no supervisado. El espacio de características multivariado se definió utilizando exclusivamente los parámetros estadísticos del canal horizontal ($X \in \mathbb{R}^{42\times 8}$), debido a su comprobada sensibilidad direccional. Se definió la sub-matriz de entrenamiento X_{train} correspondiente a las observaciones de los primeros 15 minutos ($t \in [1, 15]$). Para evitar sesgos numéricos provocados por métricas de alta magnitud, el subespacio fue normalizado utilizando una transformación *Z-score* ajustada estrictamente sobre la distribución nominal [3].

Se evaluaron tres algoritmos geométricos y estadísticos. El primero corresponde a la Distancia de Mahalanobis, una métrica de dispersión que evalúa la separación de cada nueva muestra respecto al centroide de la condición sana, ponderada por la inversa de la matriz de covarianza. El segundo es el *One-Class SVM* (OCSVM), formulado con un kernel de base radial (RBF) y un hiperparámetro de margen $\nu = 0.05$, el cual impone una frontera no lineal que encierra el espacio nominal [6]. El tercero es *Isolation Forest*, un ensamble estructurado en árboles de decisión que aísla anomalías basándose en trayectorias de partición cortas, configurado empíricamente con una tasa de contaminación del 5 % [4].

Los resultados del diagnóstico predictivo se presentan en la Figura 9. Cuantitativamente, el modelo *One-Class SVM* detectó una anomalía en el **Minuto 1**. Este resultado no constituye un fallo físico temprano, sino un fenómeno de sobreajuste topológico (*overfitting*) sobre el margen de entrenamiento; al imponer $\nu = 0.05$, el algoritmo está matemáticamente forzado a clasificar el 5 % de los datos de entrenamiento más alejados del núcleo como atípicos (falsos positivos), demostrando que este hiperparámetro es excesivamente restrictivo para la varianza basal del componente.

Por su parte, *Isolation Forest* detectó la anomalía en el **Minuto 15**, y la *Distancia de Mahalanobis* en el **Minuto 16**. Este comportamiento evidencia la diferencia analítica entre la detección de *novedad estadística* y la *falla mecánica*. Los modelos matemáticos reconocen que, a partir del minuto 15, la matriz de covarianza y la densidad geométrica de los parámetros presentan una leve deriva estocástica fuera del clúster de entrenamiento original. No obstante, al analizar la persistencia de las detecciones (Figura 9), se observa que las funciones de decisión fluctúan cerca del umbral de normalidad sin una divergencia monótona. No es hasta el intervalo del **minuto 28 al 29** que las tres métricas colapsan geométricamente superando los umbrales de manera persistente e irrecuperable. Esto demuestra empíricamente que, si bien las técnicas no supervisadas son hipersensibles a derivas operacionales microscópicas, se requiere la correlación con el comportamiento macroscópico del factor de cresta y el RMS (vistos en el minuto 29) para validar una alerta real de mantenimiento preventivo [1].

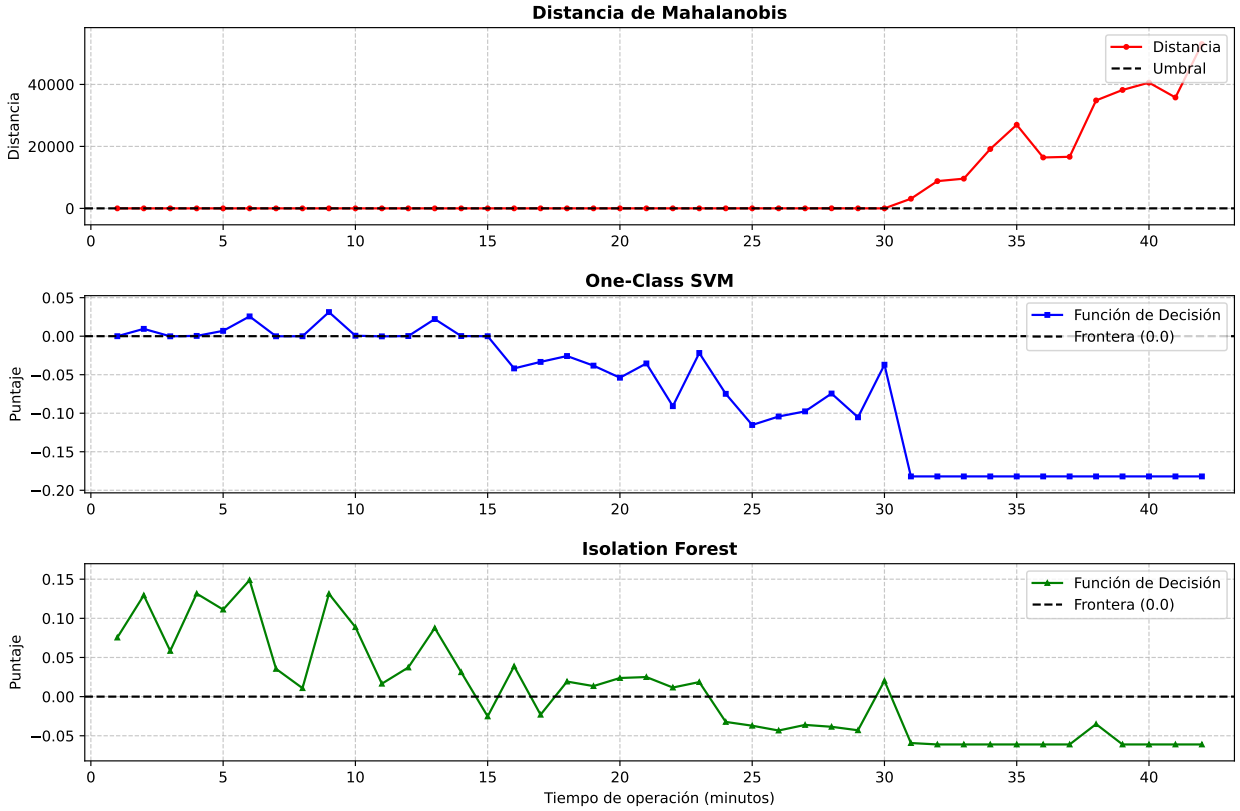


Figura 9: Comparación de funciones de decisión para los modelos de anomalía. Se visualiza la inestabilidad del OCSVM (minuto 1) y el cruce del umbral de Mahalanobis e I-Forest (minutos 16 y 15), seguidos de un quiebre geométrico persistente en el minuto 29.

2.3. Estrategia 2: Detección Espectral con Red Neuronal Autoencoder

La segunda estrategia metodológica aborda la limitación intrínseca de los parámetros temporales para detectar fallas localizadas en etapas tempranas. Para ello, se transita hacia una proyección espectral acoplada a un modelo profundo de compresión no lineal (*Autoencoder*). La señal temporal de ambos canales fue transformada utilizando el algoritmo *Fast Fourier Transform* (FFT). Dado que la energía cinemática de la falla de rodamiento se concentra fundamentalmente en la zona de media y baja frecuencia [2], se aplicó un truncamiento espectral preservando únicamente los componentes inferiores a 5000 Hz. Esto redujo la dimensionalidad, mejoró la relación señal-ruido (SNR) y constituyó un vector de entrada de alta densidad con 12800 atributos ($X_{fft} \in \mathbb{R}^{42\times12800}$).

Se diseñó una arquitectura simétrica compuesta por un *Encoder* y un *Decoder* con activaciones ReLU y una capa *bottleneck* que comprime la señal a un espacio latente de 32 dimensiones. El modelo fue entrenado exclusivamente con los primeros 15 minutos del ensayo ($t \in [1, 15]$) empleando retropropagación y minimizando el Error Cuadrático Medio (MSE), asumiendo que durante este periodo la topología espectral es completamente funcional y estacionaria [5]. Posteriormente, la matriz completa ($t \in [1, 42]$) fue proyectada sobre el modelo entrenado.

El principio operativo de esta estrategia dictamina que el *Autoencoder* reconstruirá el espectro de forma casi perfecta mientras el rodamiento mantenga su condición sana; sin embargo, al emerger armónicos desconocidos (frecuencias de falla de la pista exterior), el error de reconstrucción (MSE) divergirá agresivamente de su media histórica. Para cuantificar analíticamente la transición, se definió un umbral dinámico de normalidad establecido por la media del error de entrenamiento sumado a tres desviaciones estándar ($\mu_{MSE} + 3\sigma_{MSE}$).

Como se ilustra en la Figura 10, el sistema estocástico en estado nominal mantiene un nivel de reconstrucción estable, fluctuando por debajo de la cota superior estadística. No obstante, la arquitectura neuro-computacional detecta una **anomalía espectral persistente a partir del minuto 16**. A partir de este instante, el MSE quiebra el umbral de normalidad e inicia un crecimiento continuo. Este hallazgo contrasta de manera fundamental con la métrica de energía temporal de la Estrategia 1, demostrando empíricamente que la variación armónica ocurre significativamente antes que el incremento del valor cuadrático medio (RMS) y la manifestación del desprendimiento severo [1].

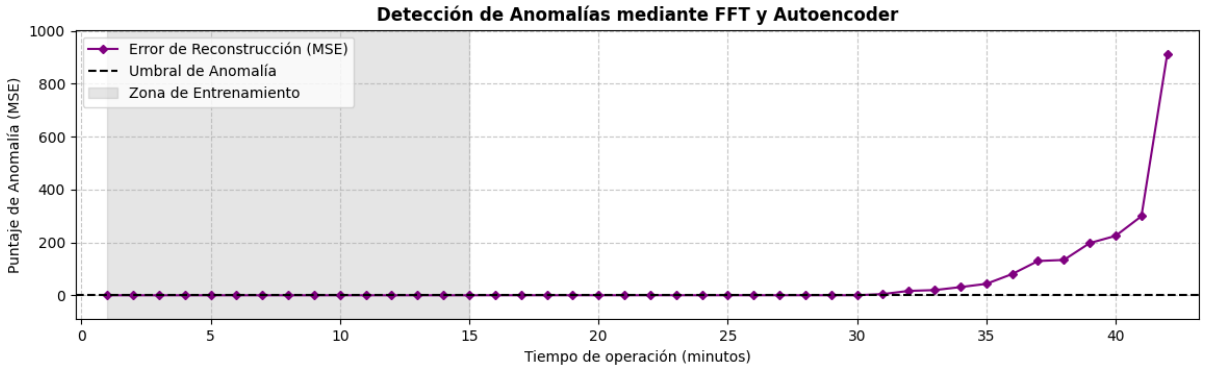


Figura 10: Error de reconstrucción topológica del modelo Autoencoder alimentado por vectores espectrales (FFT). El inicio formal de la degradación queda enmarcado en el minuto 16 tras cruzar el umbral estadístico.

3. Conclusiones

El presente estudio caracterizó con éxito la evolución del estado de salud de un rodamiento bajo ensayos de degradación acelerada *run-to-failure*, logrando determinar de forma analítica y topológica el instante de inicio de la falla utilizando datos multivariados empíricos y técnicas de *machine learning*.

A través de la **Estrategia 1 (dominio del tiempo)**, se concluye que el análisis exploratorio de descriptores de orden superior (Curtosis y Asimetría) proporciona marcadores certeros y reactivos frente a los primeros impactos transitorios inducidos por defectos localizados. Fenomenológicamente, la falla se evidencia con un comportamiento impulsivo inicial que se estabiliza posteriormente, dando paso a un incremento exponencial de métricas de disipación energética volumétrica, como el RMS y la Energía. Los modelos de agrupación topológica (*Isolation Forest* y Mahalanobis) exhibieron gran sensibilidad detectando "novedad estadística" en la frontera del entrenamiento (minutos 15 y 16 respectivamente), anticipándose sustancialmente al quiebre geométrico de la falla estructural severa, la cual se consolidó de forma macroscópica recién en el **minuto 29**.

Por otro lado, la **Estrategia 2 (dominio frecuencial + Red Neuronal)** demostró constituir un esquema de diagnóstico sumamente robusto. Al comprimir el vector espectral truncado mediante un *Autoencoder*, se logró aislar la varianza latente del componente, detectando el inicio definitivo de la anomalía armónica en el **minuto 16**. Resulta notable y analíticamente valioso que este resultado converja temporalmente de forma exacta con la Distancia de Mahalanobis. Esta validación cruzada demuestra que el minuto 16 marca el límite real donde el sistema abandona su equilibrio estocástico basal. Esto proporciona un horizonte de detección 13 minutos más temprano que los estimadores clásicos de tiempo (RMS), confirmando que la alteración de los componentes armónicos precede al desarrollo de vibraciones cinemáticas de alta intensidad

En consecuencia, se determina que la combinación de topologías espectrales (FFT) evaluadas mediante arquitecturas neuro-computacionales constituye la herramienta analítica óptima para implementar acciones de mantenimiento prescriptivo. Permite a los gestores de activos físicos contar con una validación paramétrica temprana para planificar ventanas de detención programada, previniendo intervenciones catastróficas y extendiendo el ciclo de vida de los sistemas de producción mecánica.

Referencias

[1] B. Wang, Y. Lei, N. Li, y N. Li, "A Hybrid Prognostics Approach for Estimating Remaining Useful Life of Rolling Element Bearings," *IEEE Transactions on Reliability*, pp. 1-12, 2018. DOI: 10.1109/TR.2018.2882682.

[2] R. B. Randall, *Vibration-based Condition Monitoring: Industrial, Aerospace and Automotive Applications*. Chichester, UK: John Wiley & Sons, 2011.

[3] T. Hastie, R. Tibshirani, y J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2da ed. Springer, 2009.

[4] F. T. Liu, K. M. Ting, y Z. Zhou, "Isolation Forest," en *Eighth IEEE International Conference on Data Mining*, Pisa, Italia, 2008, pp. 413-422.

[5] I. Goodfellow, Y. Bengio, y A. Courville, *Deep Learning*. MIT Press, 2016.

[6] B. Schölkopf, J. C. Platt, J. Shawe-Taylor, A. J. Smola, y R. C. Williamson, "Estimating the Support of a High-Dimensional Distribution," *Neural Computation*, vol. 13, no. 7, pp. 1443-1471, 2001.